



Universidade Estadual de Maringá
Centro de Ciências Exatas
Departamento de Física
Programa de Pós-graduação em Física

Ciência de Redes e Aprendizagem de Máquina Aplicadas ao Estudo de Redes Criminosas

Candidato: Alvaro Franco Martins
Orientador: Haroldo Valentin Ribeiro

Maringá, 22 de Março de 2024.

Sistemas complexos como uma abordagem para estudar o crime organizado

O uso da ciência da complexidade tem sido defendido por diversos autores como uma abordagem ideal para investigar crime econômico, crime organizado e corrupção:

Statistical physics of crime: A review

Maria R. D'Orsogna^{a,b}, Matjaž Perc^{c,d,e,*}

Complexity science approach to economic crime

János Kertész¹ and Johannes Wachs^{2,3}

Scaling laws in the dynamics of crime growth rate

Luiz G.A. Alves¹, Haroldo V. Ribeiro¹, Renio S. Mendes¹

Corruption risk in contracting markets: a network science perspective

Johannes Wachs¹ · Mihály Fazekas² · János Kertész³

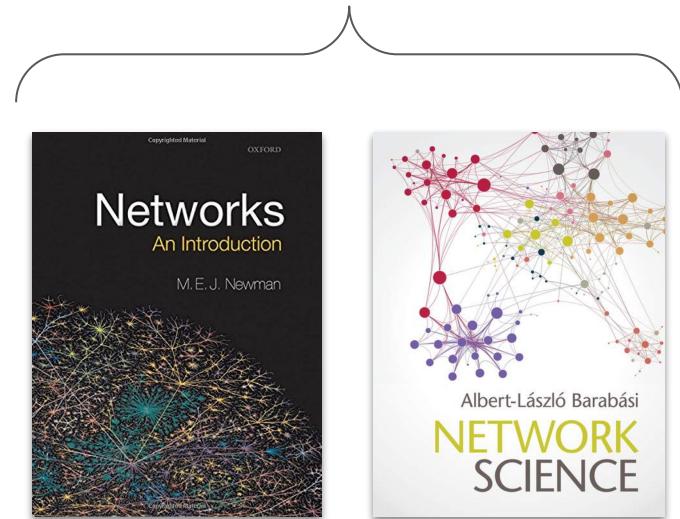
Unveiling relationships between crime and property in England and Wales via density scale-adjusted metrics and network tools

Haroldo V. Ribeiro¹, Quentin S. Hanley, Dan Lewis

Sistemas complexos como uma abordagem para estudar o crime organizado

Em nosso estudo, a representação de sistemas complexos está embasada em ciência de redes

- **Vértices** representam *criminosos ou suspeitos*;
- **Conexões** indicam as *parcerias entre esses indivíduos*.



Isso possibilita a descrição adequada das interações entre criminosos por meio de ferramentas e métodos da ciência de redes.

Sistemas complexos como uma abordagem para estudar o crime organizado

Essa abordagem já se mostrou eficaz:

Topology, robustness, and structural controllability of the Brazilian Federal Police criminal intelligence network

[Bruno Requião da Cunha](#) & [Sebastián Gonçalves](#)

Analyzing the Bills-Voting Dynamics and Predicting Corruption-Convictions Among Brazilian Congressmen Through Temporal Networks

[Tiago Colliri](#) & [Liang Zhao](#)

Corruption and complexity: a scientific framework for the analysis of corruption networks

[Issa Luna-Pla](#) & [José R. Nicolás-Carlock](#)

The dynamical structure of political corruption networks

[Haroldo V Ribeiro](#), [Luiz G A Alves](#), [Alvaro F Martins](#), [Ervin K Lenzi](#), [Matjaž Perc](#)

A network approach to cartel detection in public auction markets

[Johannes Wachs](#) & [János Kertész](#)

Fast Fragmentation of Networks Using Module-Based Attacks

[Bruno Requião da Cunha](#), [Juan Carlos González-Avella](#), [Sebastián Gonçalves](#)

The Relative Ineffectiveness of Criminal Network Disruption

[Paul A. C. Duijzer](#), [Victor Kashirin](#) & [Peter M. A. Sloot](#)

Organized crime behavior of shell-company networks in procurement: prevention insights for policy and reform

[J. R. Nicolás-Carlock¹](#) • [I. Luna-Pla²](#)

The ties that bribe: Corruption's embeddedness in Chicago organized crime*

[Jared Joseph](#) & [Chris M. Smith](#)

Assessing police topological efficiency in a major sting operation on the dark web

[Bruno Requião da Cunha](#), [Pádraig MacCarron](#), [Jean Fernando Passold](#), [Luiz Walmocyr dos Santos Jr.](#), [Kleber A. Oliveira](#) & [James P. Gleeson](#)

Political corruption and the congestion of controllability in social networks

[Philip C. Solimine](#)

Communities in criminal networks: A case study

[Francesco Calderoni^a](#), [Domenico Brunetto^b](#), [Carlo Piccardi^{c,d}](#)

Conspiracy of Corporate Networks in Corruption Scandals

 [J. R. Nicolás-Carlock*](#)  [I. Luna-Pla](#)

AI against money laundering networks: the Colombian case

[Olmer García-Bedoya](#), [Oscar Granados](#), [José Cardozo Burgos](#)

No entanto, ainda existiam lacunas relacionadas à identificação de propriedades comuns de redes criminosas.

Article | [Open Access](#) | Published: 27 April 2022

Universality of political corruption networks

[Alvaro F. Martins](#), [Bruno R. da Cunha](#), [Quentin S. Hanley](#), [Sebastián Gonçalves](#), [Matjaž Perc](#)✉ & [Haroldo V. Ribeiro](#)

[Scientific Reports](#) **12**, Article number: 6858 (2022) | [Cite this article](#)

2819 Accesses | **5** Citations | **21** Altmetric | [Metrics](#)

Conjuntos de dados



Corrupção espanhola

- 30 anos (de 1989 a 2018);
- 437 escândalos de corrupção;
- 2753 pessoas envolvidas.

Corrupção brasileira

- 28 anos (de 1987 a 2014);
- 65 escândalos de corrupção;
- 404 pessoas envolvidas.

Distribuição acumulada do número de pessoas por escândalo

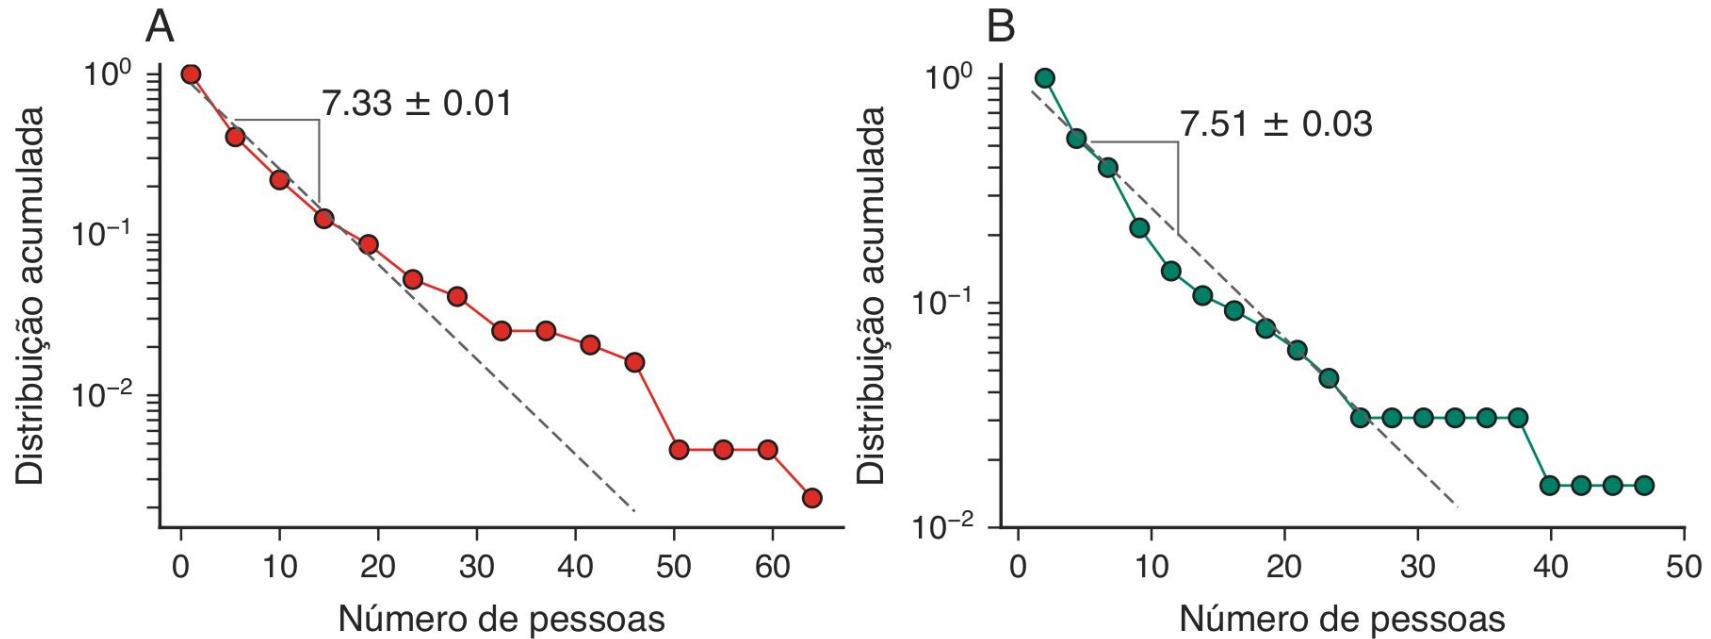
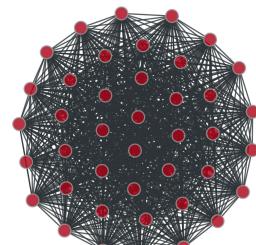


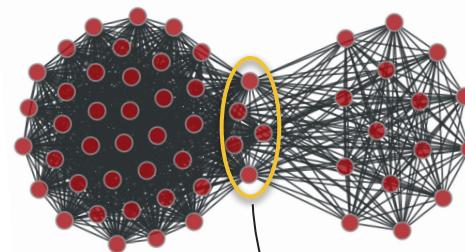
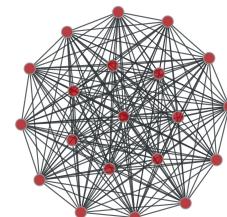
Figura 1: Distribuição acumulada complementar do número de implicados em casos de corrupção da (A) Espanha e (B) do Brasil.

Formação das redes de corrupção

Gürtel/Primeira Época (1989)
41 envolvidos



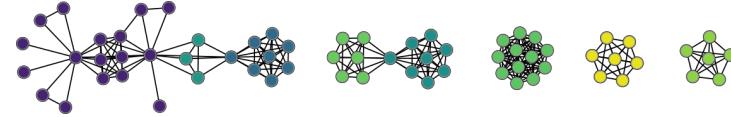
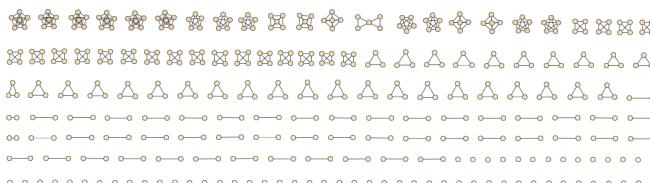
Gürtel/Arganda (1998)
20 envolvidos



5 envolvidos reincidentes

Redes de corrupção espanhola e brasileira

2753 vértices,
27545 ligações



404 vértices,
3549 ligações

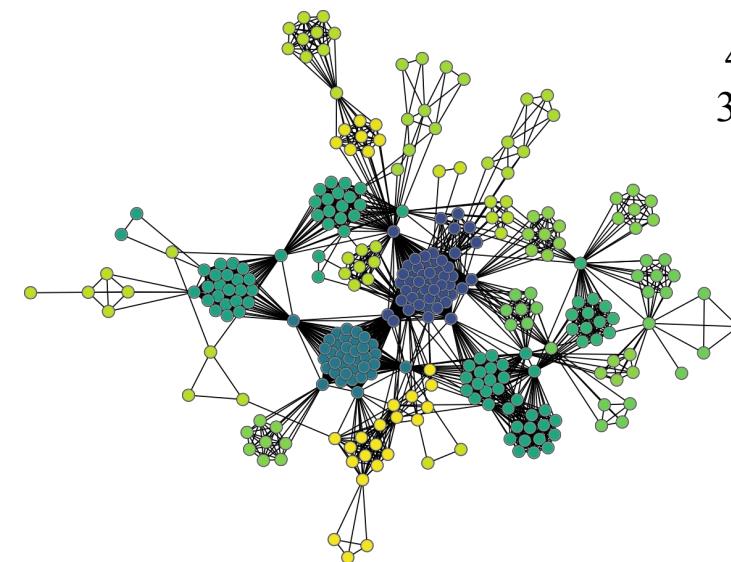


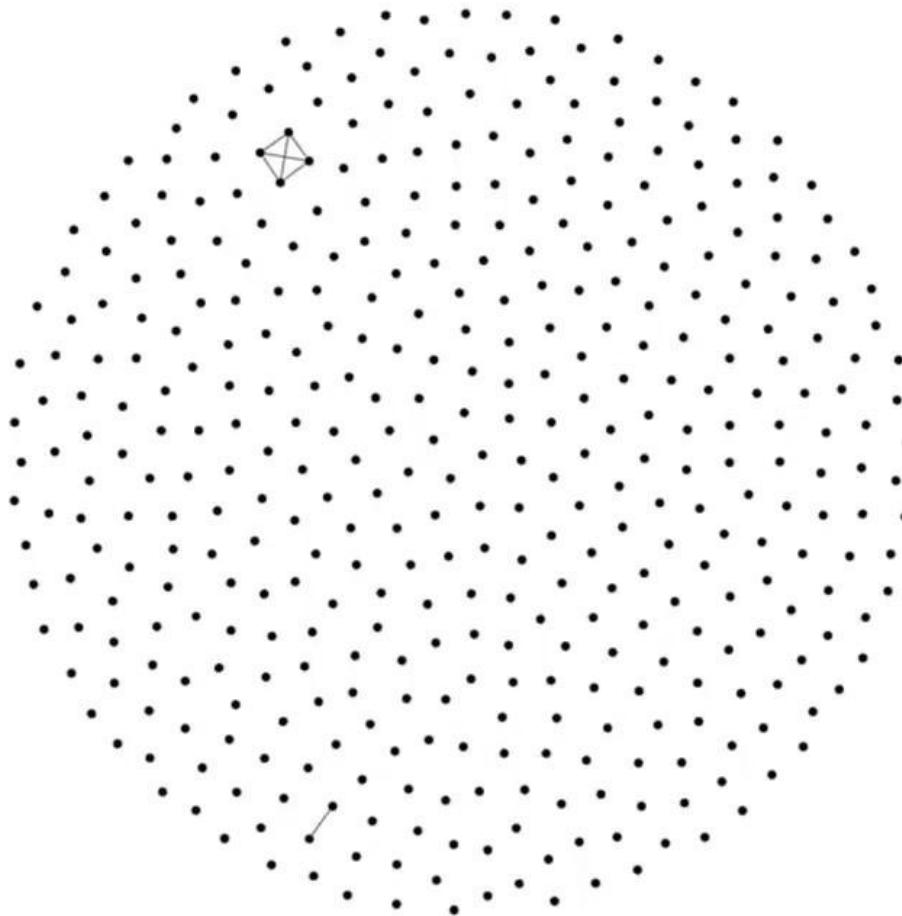
Figura 2: Visualização das redes de corrupção formadas por pessoas envolvidas em escândalos políticos da Espanha e do Brasil.

Comparação entre as redes de corrupção

Medidas estruturais das redes de corrupção

	Espanha	Brasil	Espanha (maior componente)	Brasil (maior componente)
Coeficiente de agrupamento	0.91	0.93	0.94	0.93
Coeficiente de assortatividade	0.74	0.53	0.59	0.50
Densidade	0.007	0.044	0.025	0.06
Comprimento médio do caminho			5.11	2.99

Aspecto temporal das redes de corrupção



Distribuições de grau das redes ao longo dos anos

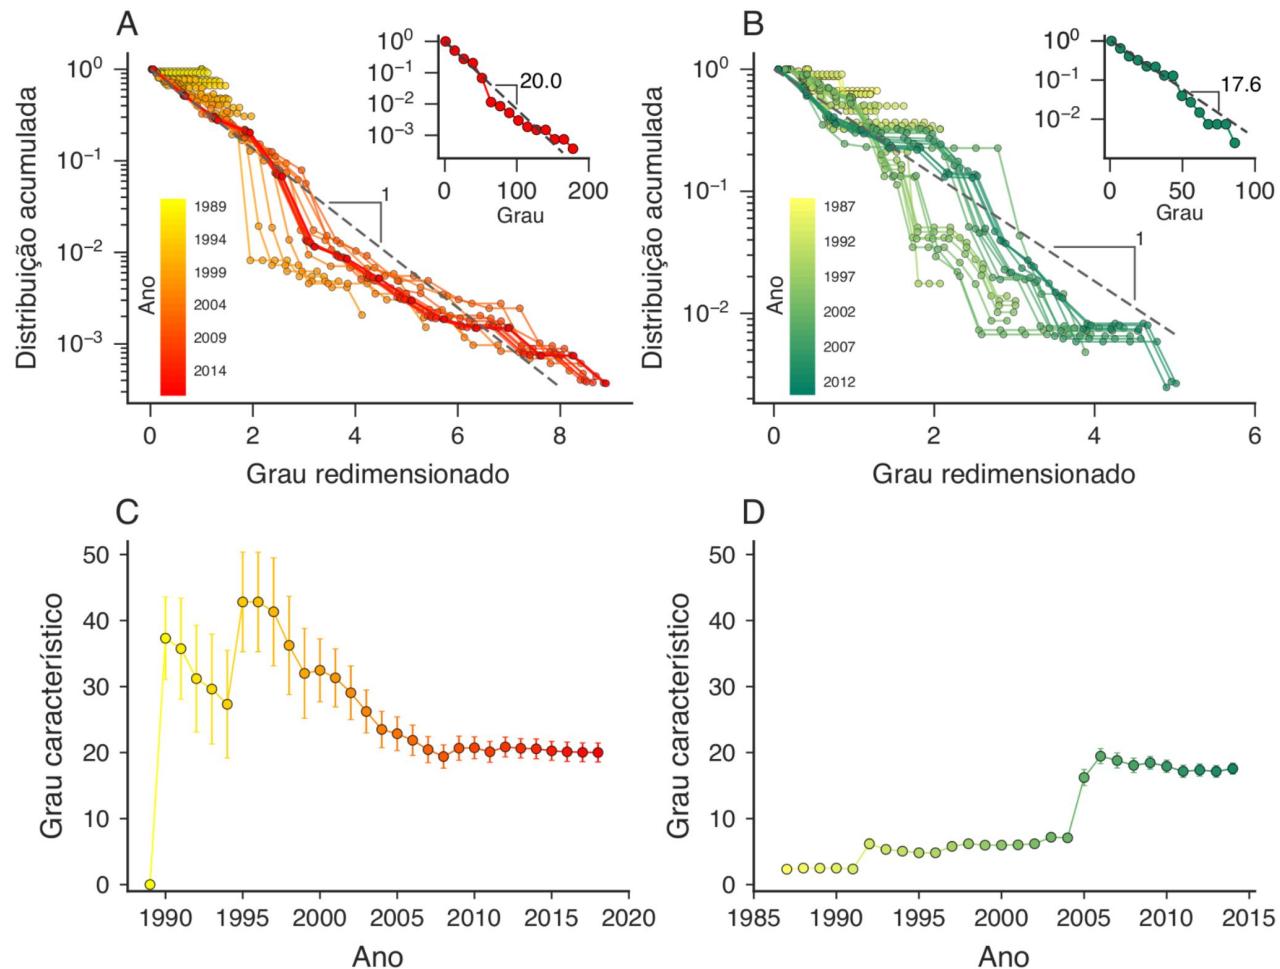


Figura 3: Distribuições acumuladas complementares de grau das redes de corrupção (A) espanhola e (B) brasileira. Evolução do grau característico das redes de corrupção (C) espanhola e (D) brasileira.

Evolução temporal do tamanho das duas maiores componentes conectadas

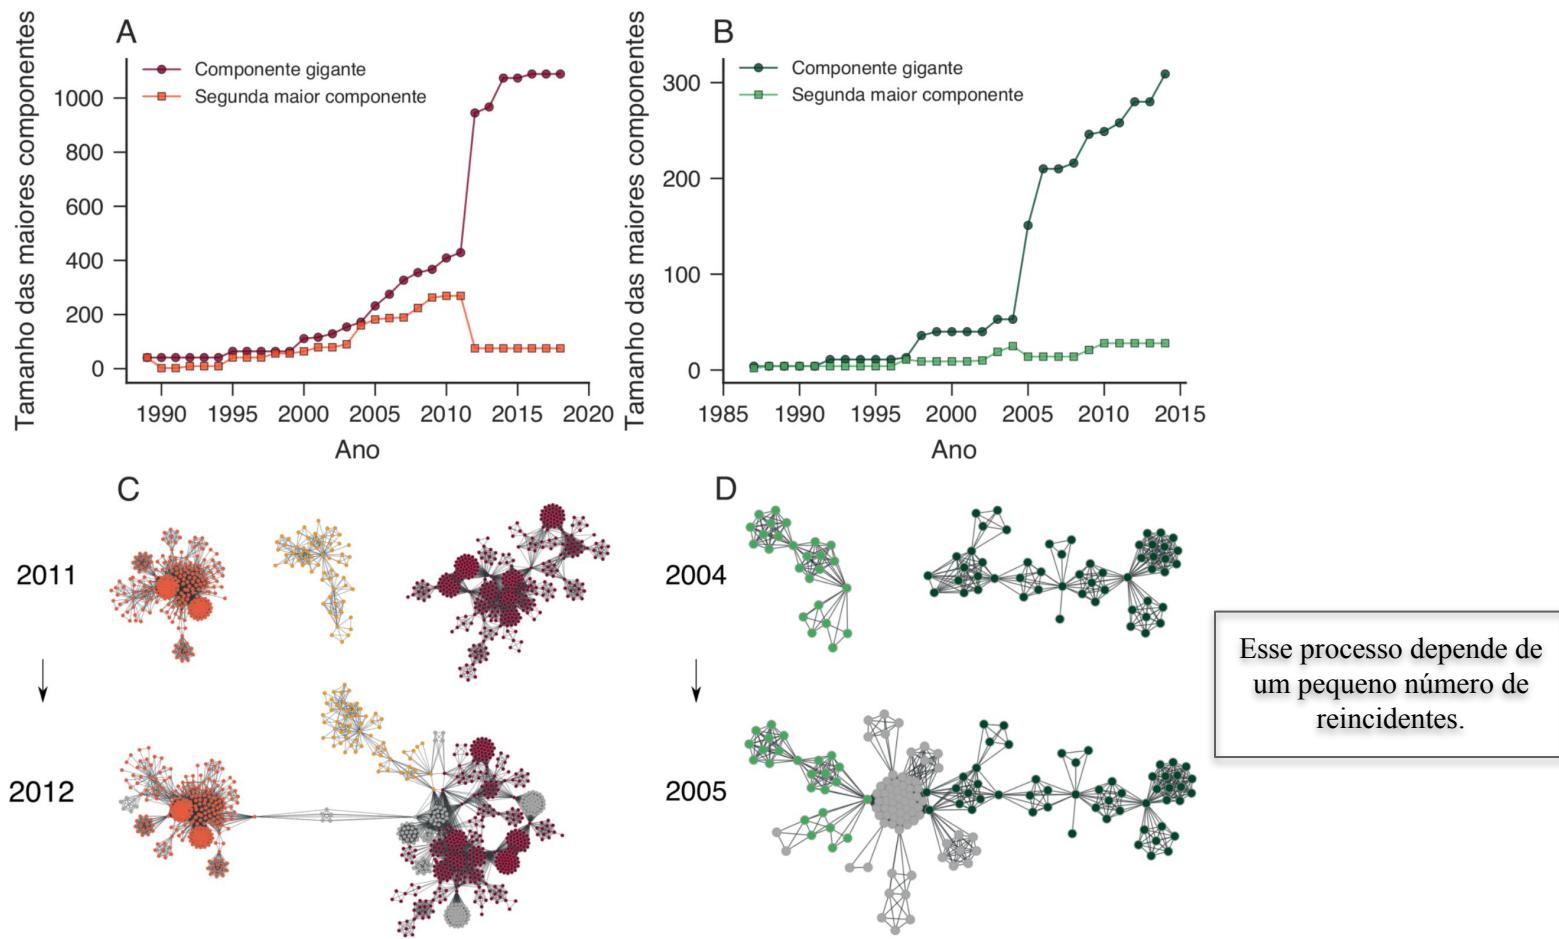
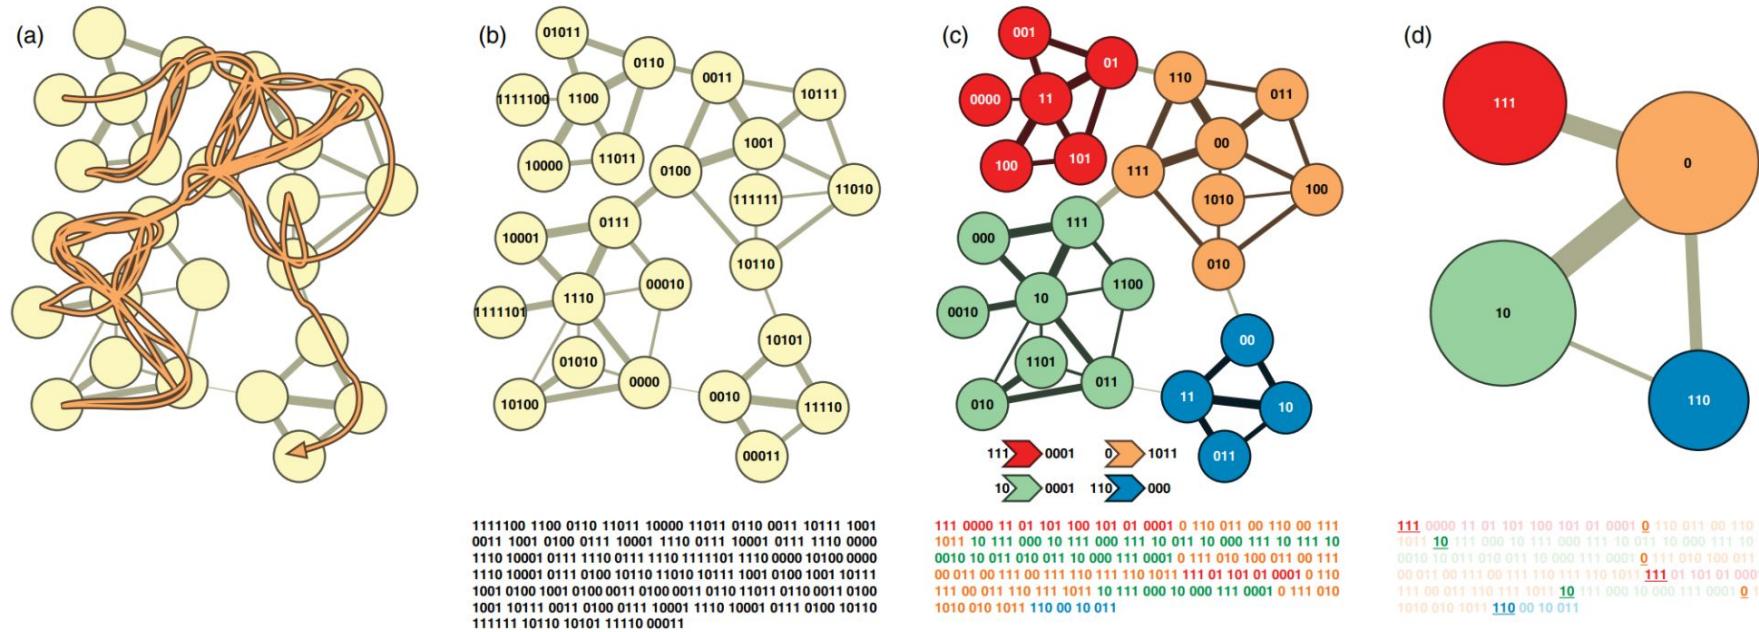


Figura 4: Evolução temporal do tamanho das maiores componentes das redes de corrupção (A) espanhola e (B) brasileira. Processo de coalescência entre as maiores componentes das redes de corrupção (C) espanhola e (D) brasileira.

Detecção de estrutura de comunidades nas redes de corrupção

The map equation

M. Rosvall^{1,a}, D. Axelsson¹, and C.T. Bergstrom²



Comportamentos lineares nas redes de corrupção

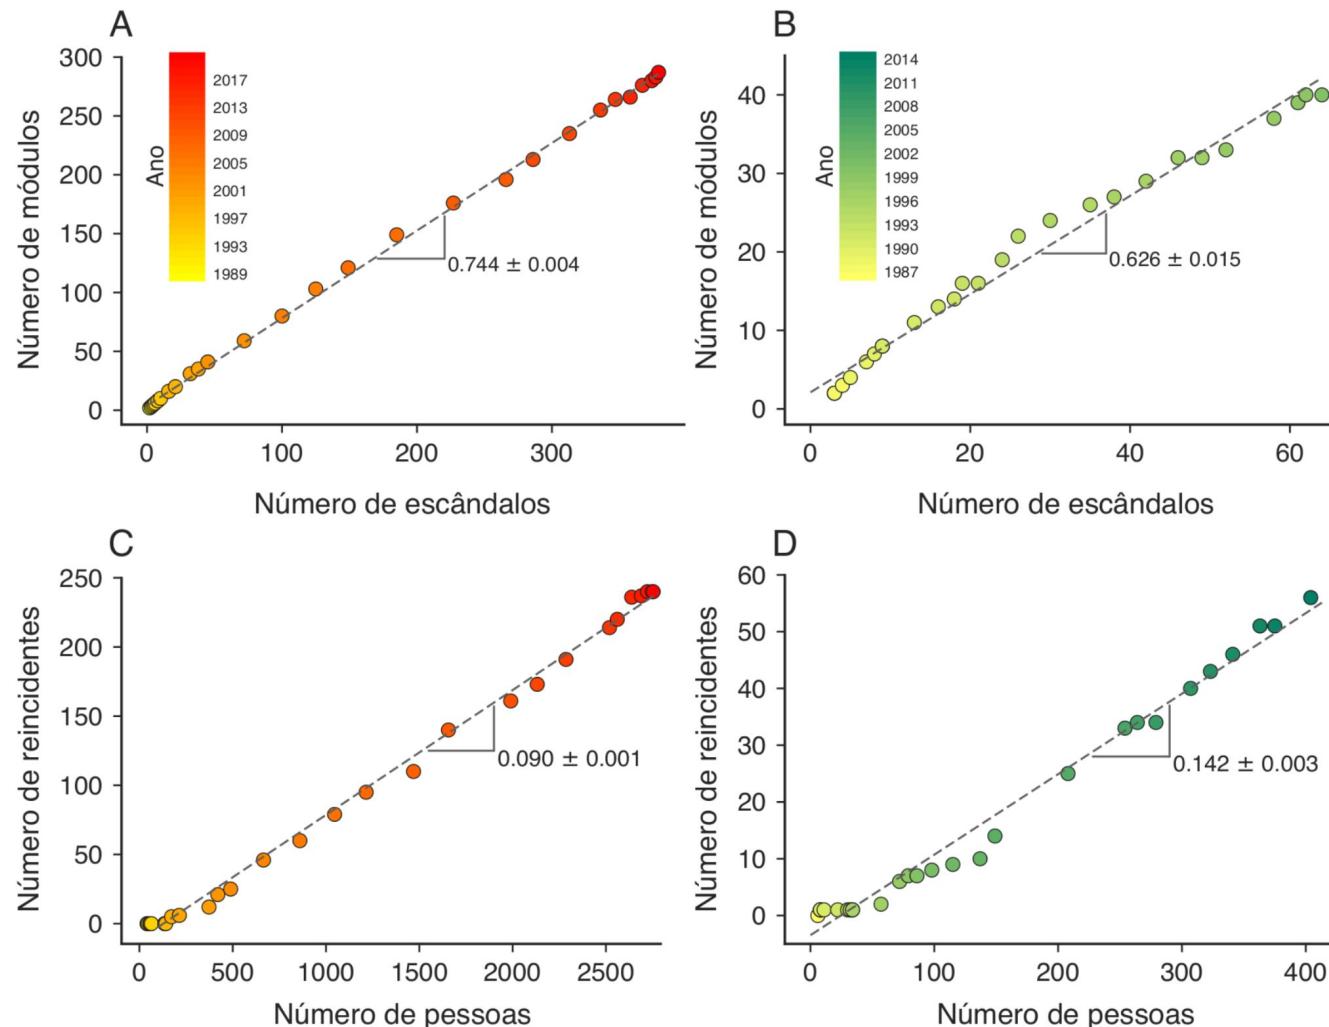
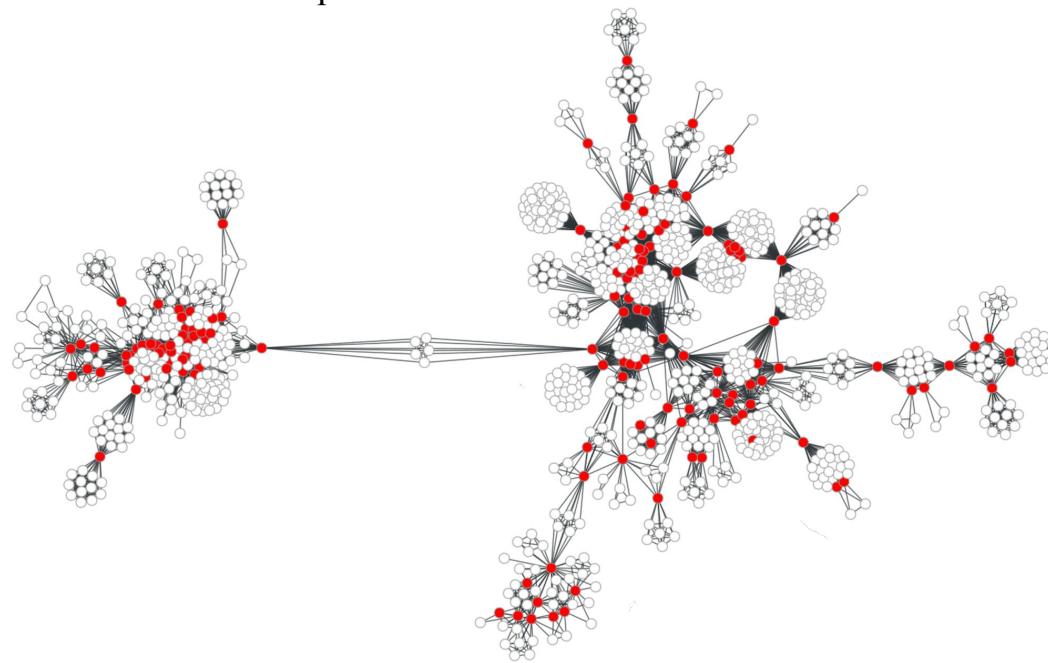


Figura 5: Relação entre o número de módulos e de escândalos para cada ano das redes de corrupção (A) espanhola e (B) brasileira. Associação entre o número de agentes reincidentes e o número total de pessoas para cada ano das redes de corrupção (C) espanhola e (D) brasileira.

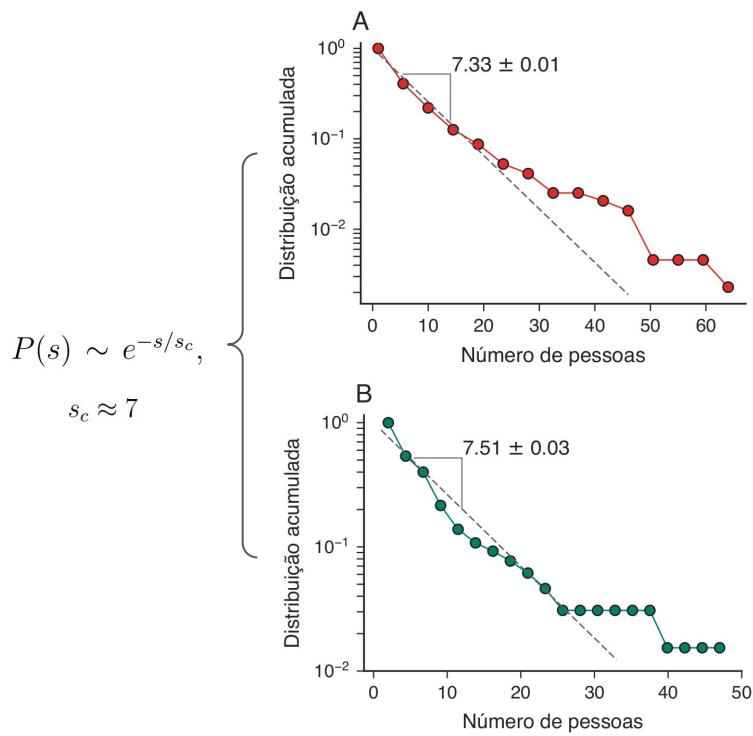
O papel dos envolvidos reincidentes em escândalos de corrupção

- Fazem a conexão entre dois ou mais escândalos de corrupção;
- Responsáveis pelo crescimento e estrutura macroscópica da rede;
- Fundamentais para o processo tipo coalescência observado;
- Formam o “esqueleto” da rede.

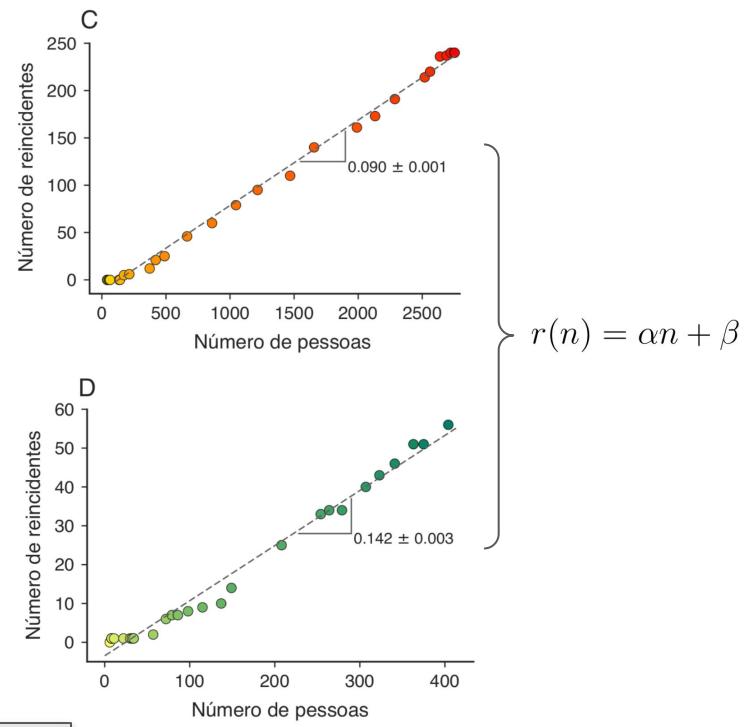


Modelo computacional para o crescimento de redes de corrupção

Número típico
de envolvidos por escândalos



Número de reincidentes
por quantidade total de vértices



Porcentagem de reincidentes
em mais de dois escândalos
 $p_a = 0.025$

Algoritmo do modelo de redes de corrupção

- Inicializar uma rede vazia ($n = 0$)

Repetir um dado número de vezes:

- Gerar um grafo totalmente conectado de tamanho sorteado de uma distribuição exponencial;
 - Adicionar o grafo à rede;
 - Definir o número de novos agentes reincidentes usando o total de agentes reincidentes $r(n) = \alpha n + \beta$
- Se o número de novos agentes reincidentes for maior que zero:

 Repetir para cada novo agente reincidente:

- Com probabilidade $1 - p_a$, escolher aleatoriamente dois vértices não reincidentes para se tornarem um mesmo vértice reincidente;
- Com probabilidade p_a , escolher aleatoriamente um vértice reincidente e um vértice não reincidente para se tornarem um mesmo vértice reincidente;

Comportamento do modelo de redes de corrupção

Comportamento do modelo de redes de corrupção

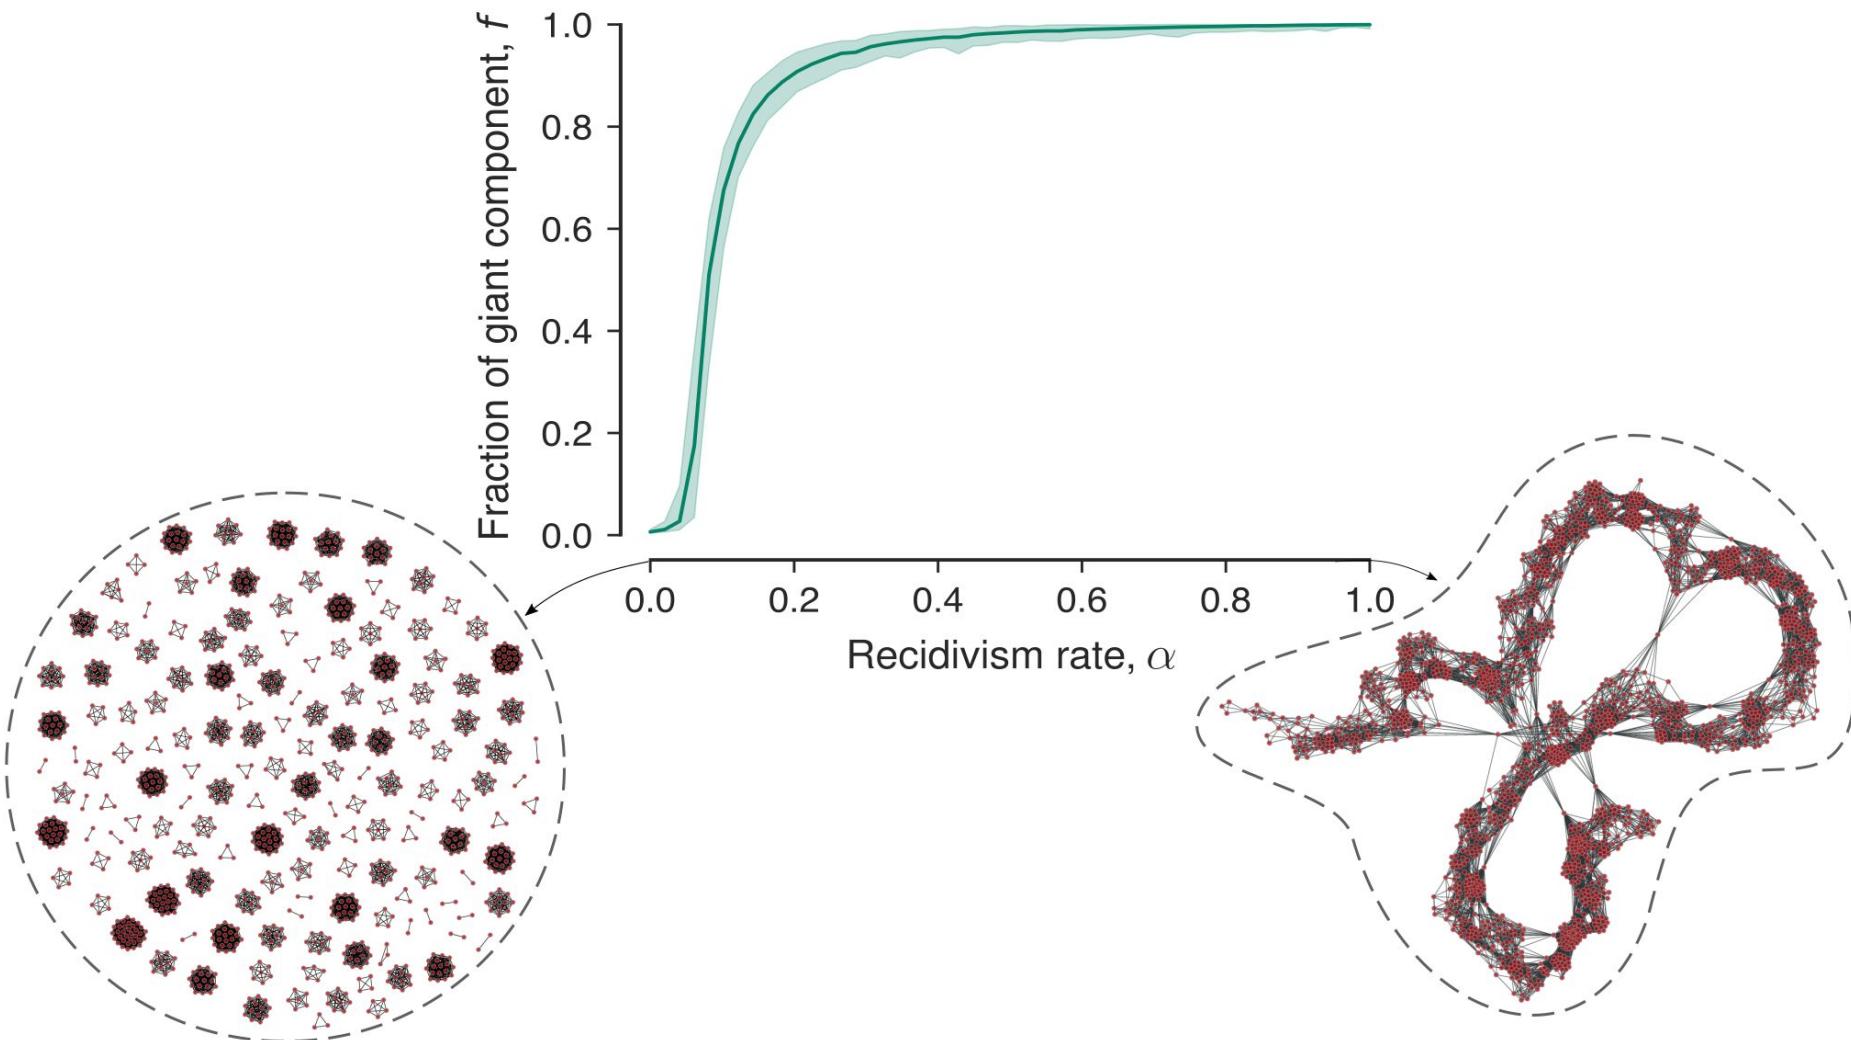
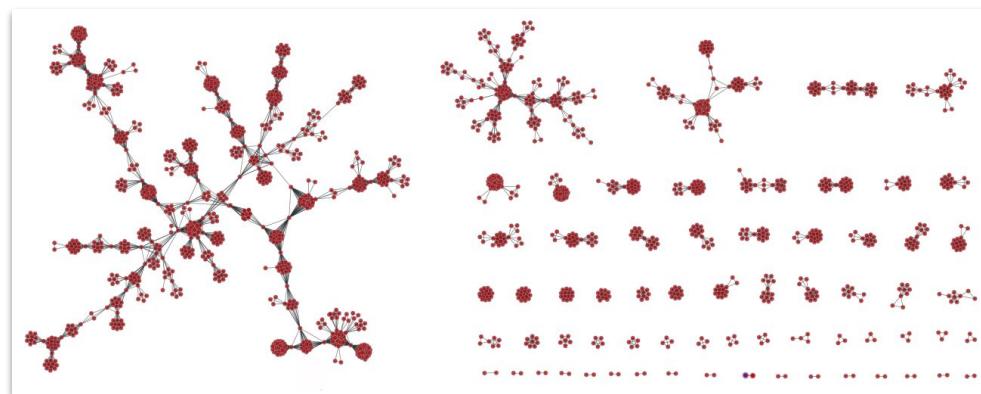
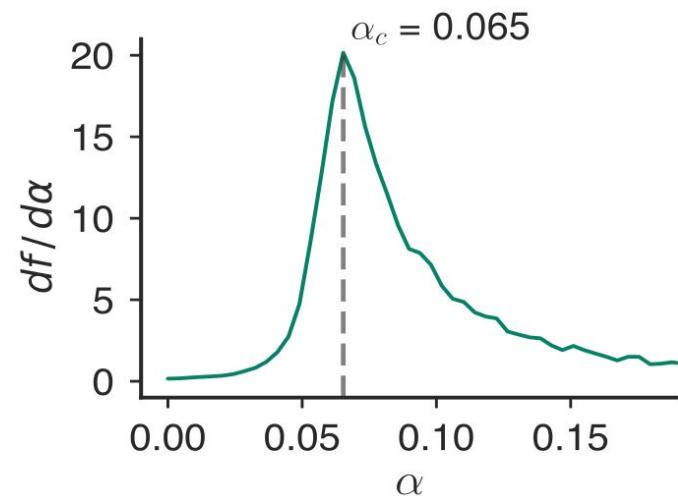
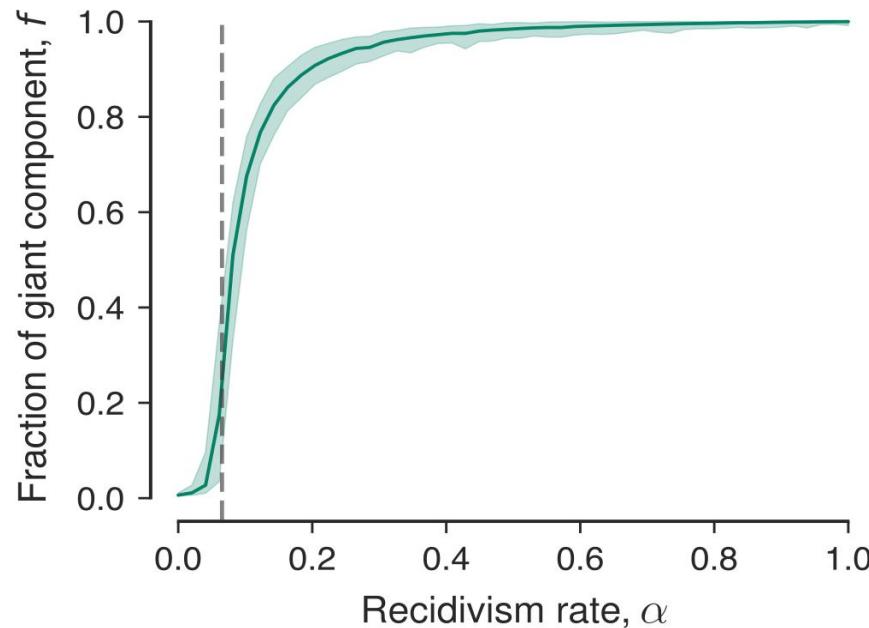


Figura 6: Tamanho médio da maior componente das redes obtidas via nosso modelo em função da taxa de reincidência.

Comportamento do modelo de redes de corrupção



Comportamento do modelo de redes de corrupção

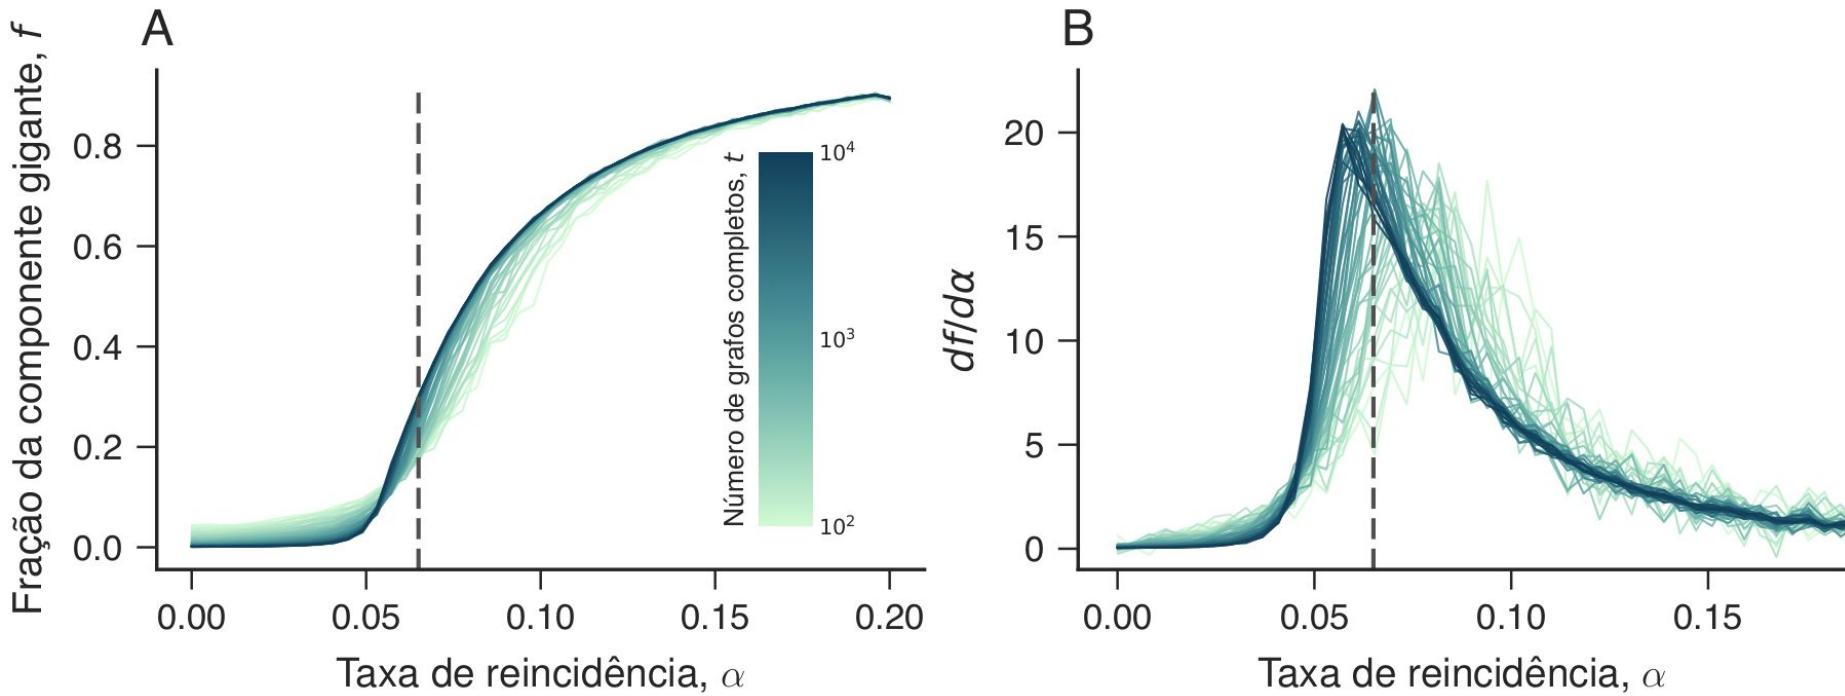


Figura 7: (A) Fração média da componente gigante das redes simuladas em função da taxa de reincidência variando o número de grafos completos. (B) Derivada da quantidade anterior em relação à taxa de reincidência.

Comparação com resultados empíricos

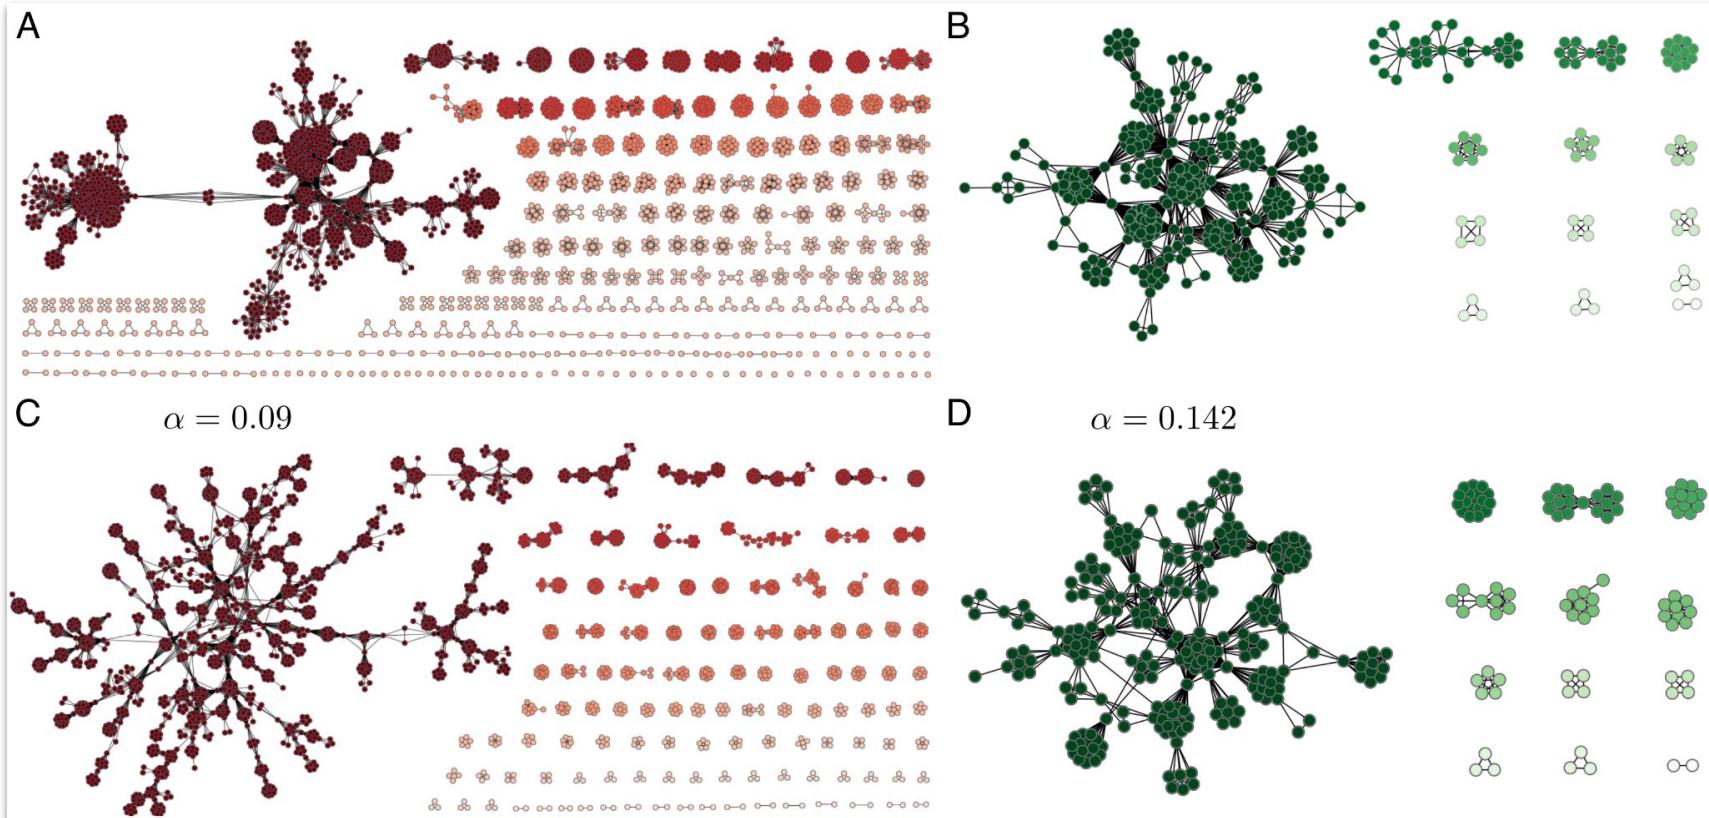


Figura 8: Comparação visual entre as redes de corrupção espanhola (A) e brasileira (B) e redes típicas geradas por nosso modelo usando os valores empíricos da taxa de reincidência da Espanha (C) e do Brasil (D).

Comparação com resultados empíricos

Medidas estruturais das redes de corrupção simuladas e empíricas

	Espanha (simulação)	Brasil (simulação)	Espanha (simulação, maior componente)	Brasil (simulação, maior componente)
Coeficiente de agrupamento	0.91 (0.949 ± 0.003)	0.93 (0.938 ± 0.008)	0.94 (0.945 ± 0.004)	0.93 (0.938 ± 0.007)
Coeficiente de assortatividade	0.74 (0.76 ± 0.01)	0.53 (0.67 ± 0.03)	0.59 (0.69 ± 0.02)	0.50 (0.63 ± 0.04)
Densidade	0.007 (0.0042 ± 0.0002)	0.044 (0.030 ± 0.003)	0.025 (0.0084 ± 0.0009)	0.06 (0.043 ± 0.008)
Comprimento médio do caminho			5.11 (9.17 ± 1.01)	2.99 (4.87 ± 0.55)

Comparação com resultados empíricos

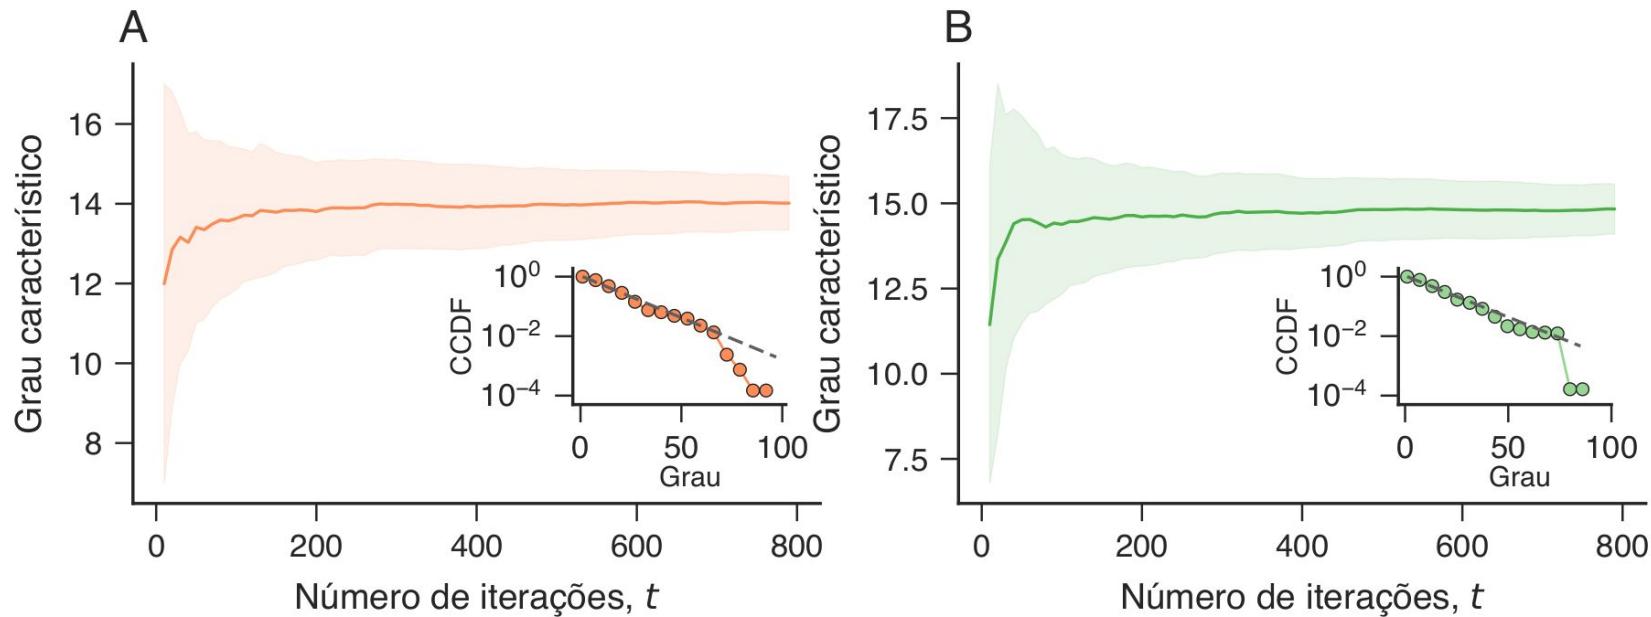


Figura 9: (A) Valor médio do grau característico usando a taxa de reincidência espanhola em função do número de iterações. A inserção mostra a distribuição acumulada complementar de grau após 800 iterações do modelo. O painel (B) mostra a mesma análise com o mesmo número de simulações, mas usando a taxa de reincidência brasileira.

Comparação com resultados empíricos

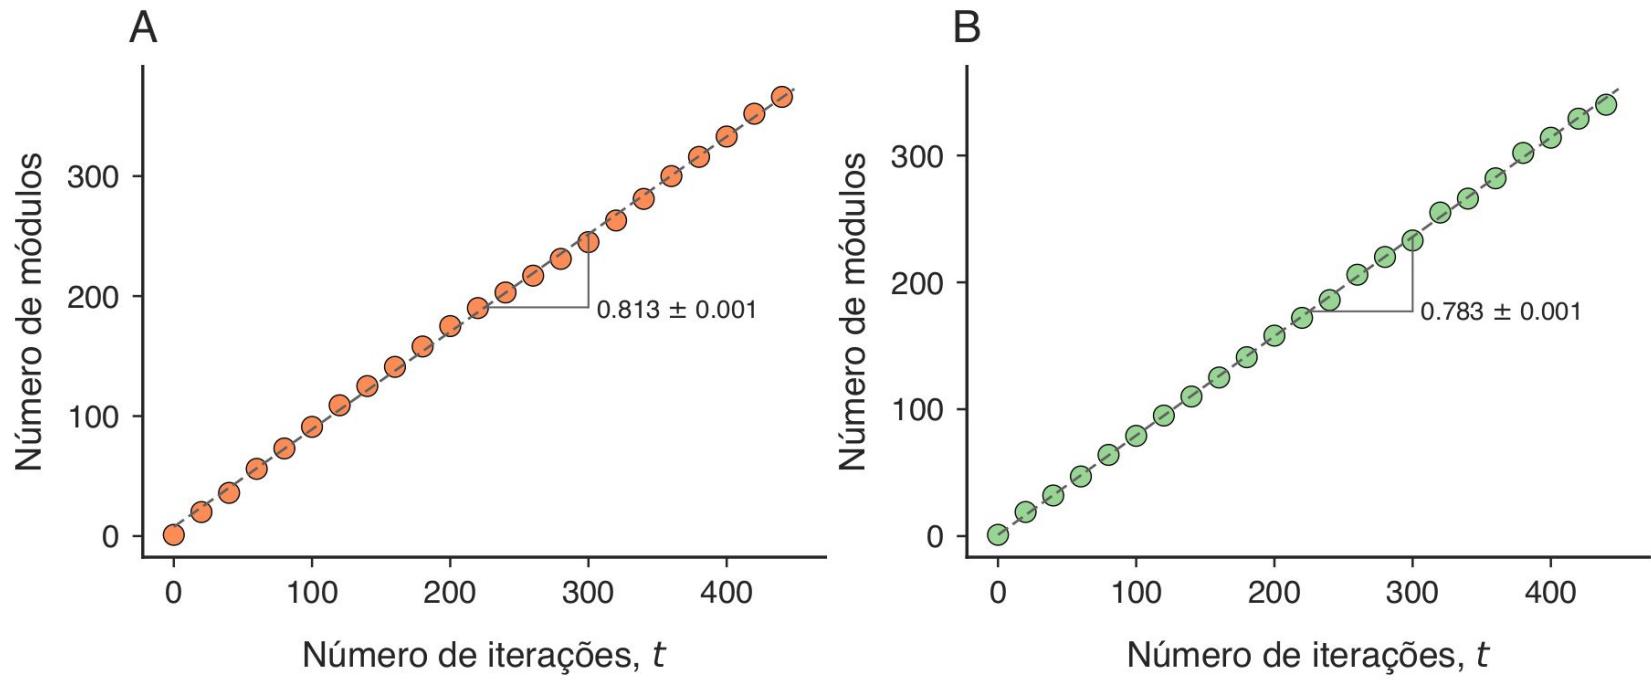


Figura 10: Exemplos típicos da associação linear entre o número de módulos e o total de escândalos para redes simuladas usando as taxas de reincidência espanhola (A) e brasileira (B).

Comparação com resultados empíricos

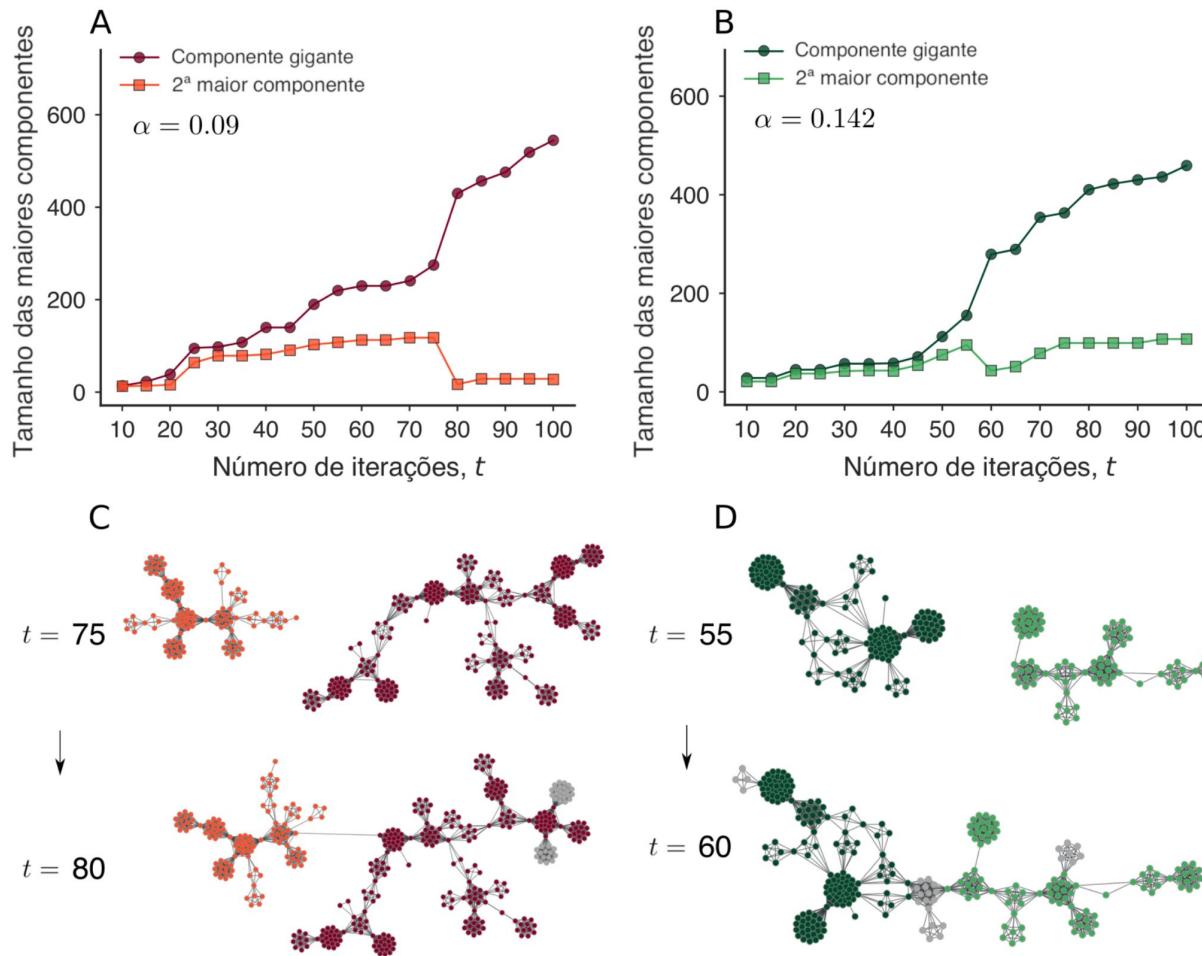


Figura 11: Exemplos típicos da evolução do tamanho das maiores componentes das redes simuladas usando as taxas de reincidência espanhola (A) e brasileira (B). Os painéis (C) e (D) mostram visualizações das componentes antes e depois das mudanças abruptas.

Robustez dos resultados

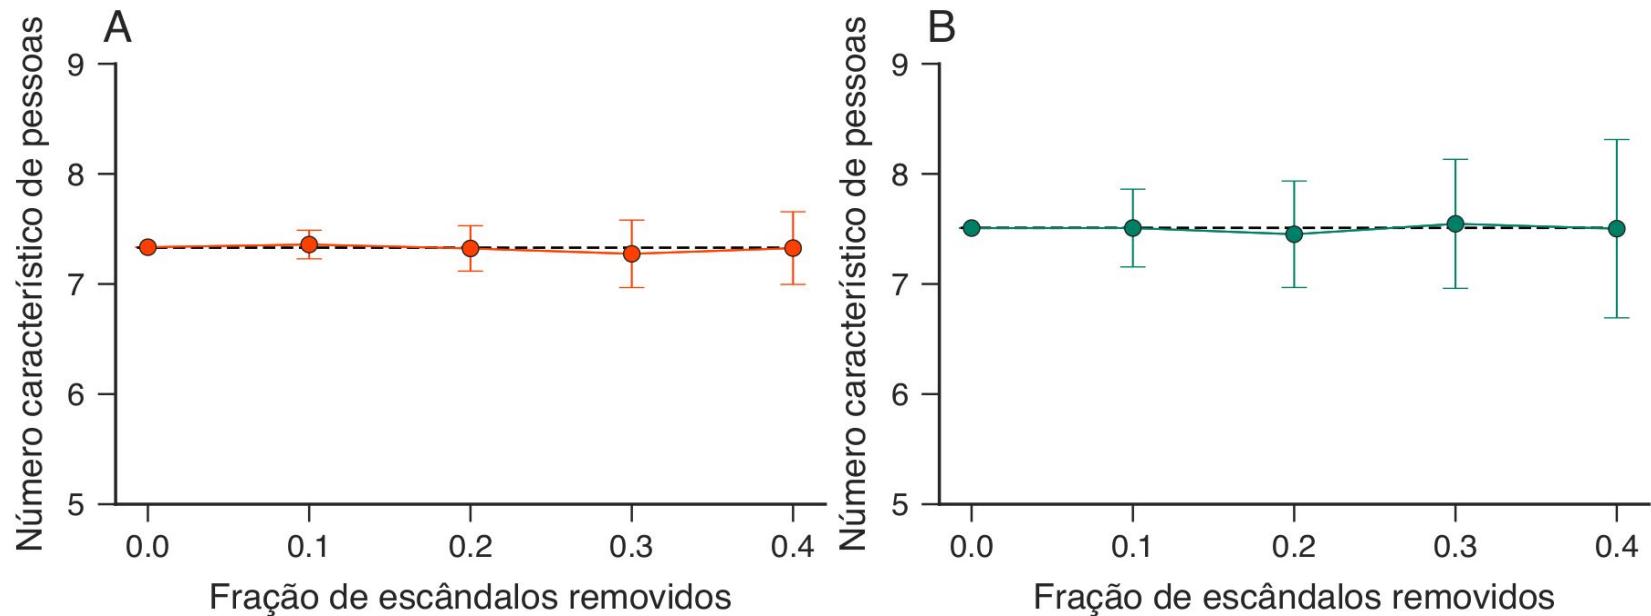


Figura 12: Estimativas do número característico de pessoas envolvidas em escândalos de corrupção na (A) Espanha e no (B) Brasil em função da fração de escândalos removidos.

Robustez dos resultados

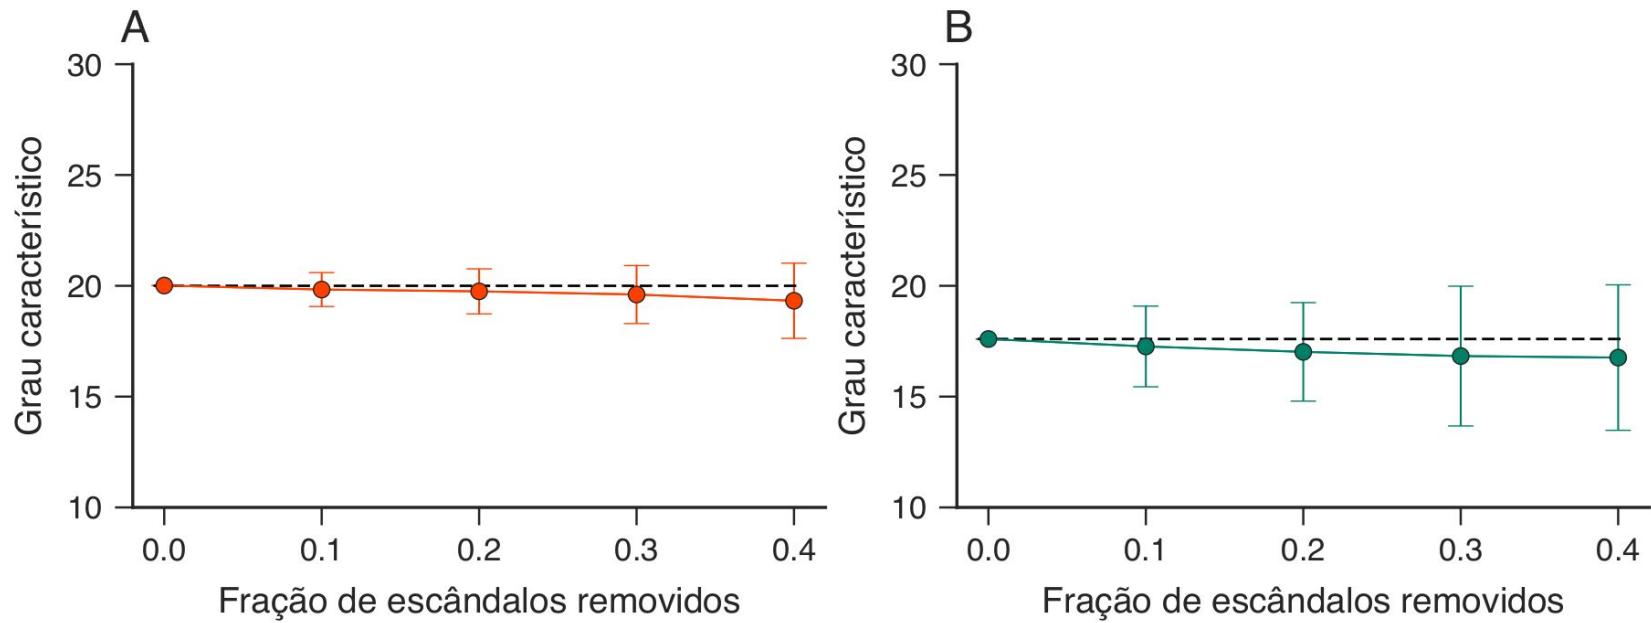


Figura 13: Estimativas do grau característico para a última etapa das redes de corrupção (A) espanhola e (B) brasileira em função da fração de escândalos removidos.

Robustez dos resultados

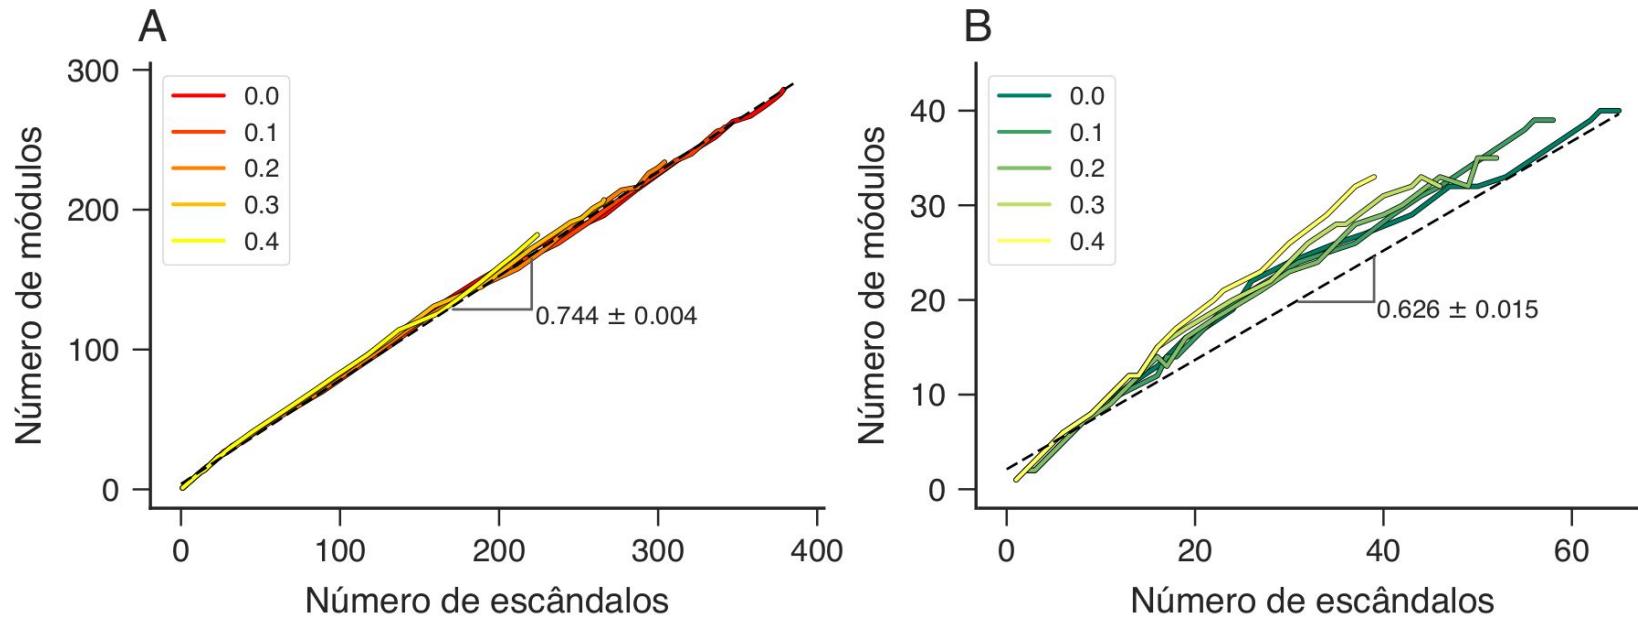


Figura 14: As curvas mostram as relações entre o número de módulos e o número de escândalos para cada ano das redes (A) espanhola e (B) brasileira sob diferentes frações de escândalos removidos.

Robustez dos resultados

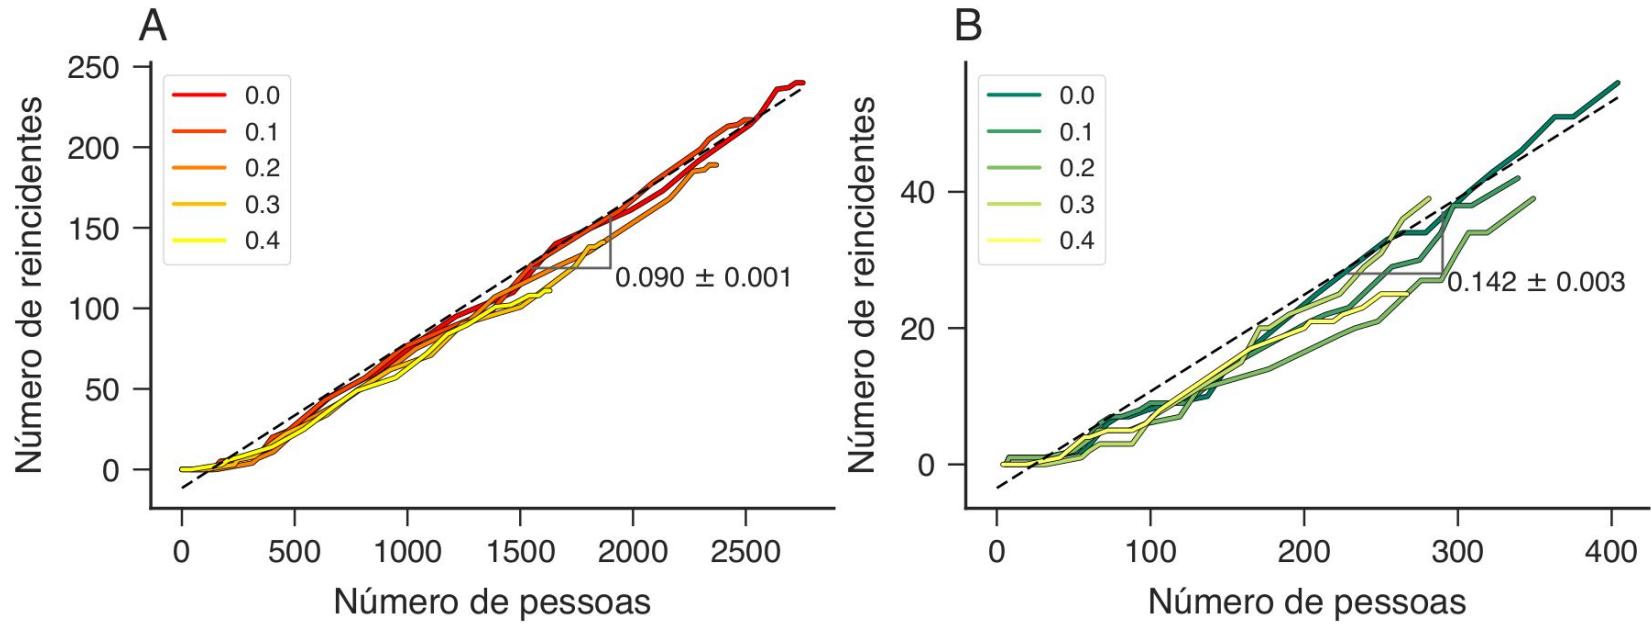


Figura 15: As curvas mostram a relação entre o número de agentes reincidentes e o número total de pessoas ao longo do crescimento das redes (C) espanhola e (D) brasileira sob diferentes frações de escândalos removidos.

Article | [Open Access](#) | Published: 21 September 2022

Machine learning partners in criminal networks

[Diego D. Lopes](#), [Bruno R. da Cunha](#), [Alvaro F. Martins](#), [Sebastián Gonçalves](#), [Ervin K. Lenzi](#), [Quentin S. Hanley](#), [Matjaž Perc](#)✉ & [Haroldo V. Ribeiro](#)✉

[Scientific Reports](#) **12**, Article number: 15746 (2022) | [Cite this article](#)

2592 Accesses | **5** Citations | **10** Altmetric | [Metrics](#)

Conjuntos de dados

Redes de corrupção +

Rede de inteligência policial

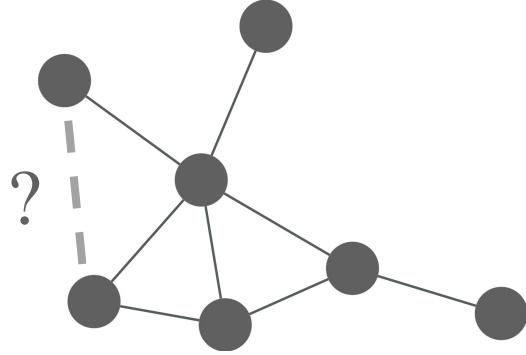
Rede completa: 23666 vértices e 35930 ligações;

Maior componente: 8894 vértices, 17827 ligações (associações entre os envolvidos classificadas entre: criminosa, mista e não criminosa).

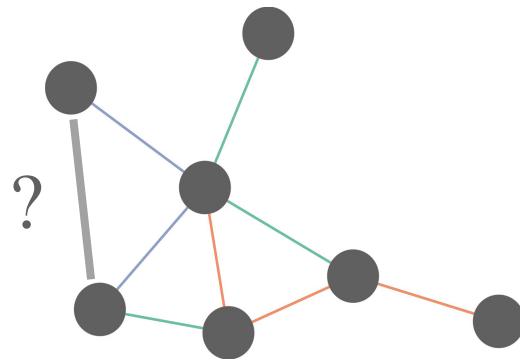
Rede de crimes financeiros

Rede completa com 1126 vértices e 1299 ligações associadas a valores de transações financeiras entre pessoas ou empresas.

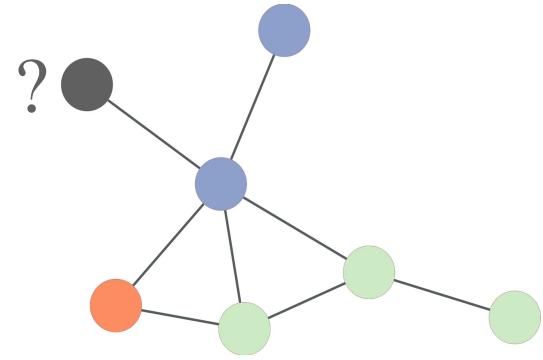
Tarefas de aprendizagem de máquina em redes



Previsão de ligações



Previsão de variáveis
associadas às ligações



Classificação de vértices

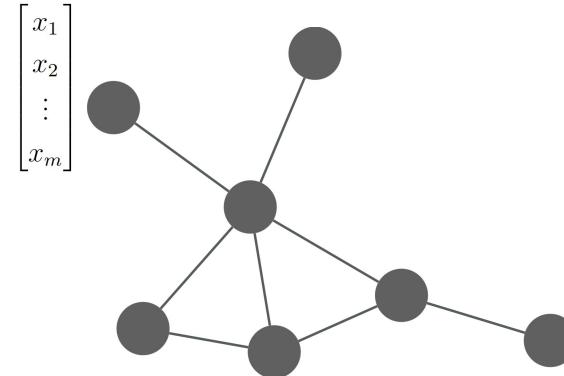
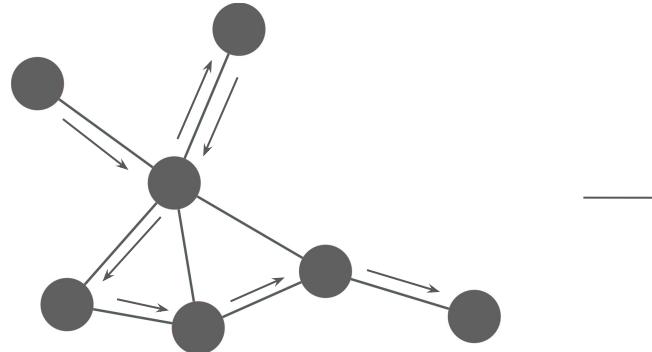
Método de representação de grafos

node2vec: Scalable Feature Learning for Networks

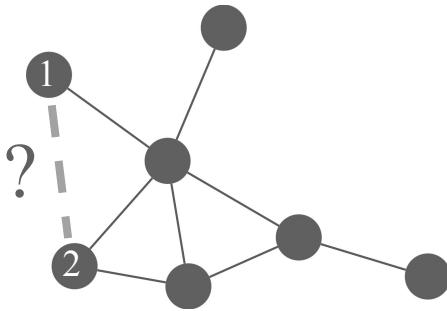
Aditya Grover
Stanford University
adityag@cs.stanford.edu

Jure Leskovec
Stanford University
jure@cs.stanford.edu

Random walks na rede

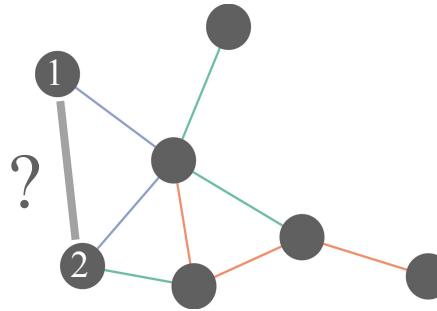


Método de representação de grafos



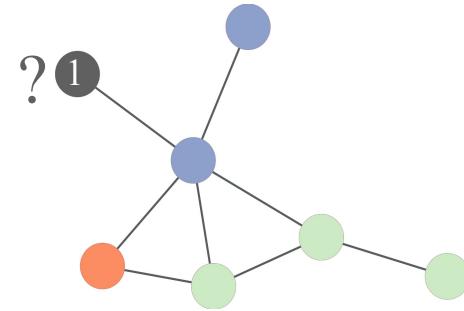
Previsão de ligações

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix}_1, \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix}_2$$



Previsão de variáveis associadas às ligações

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix}_1, \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix}_2$$



Classificação de vértices

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix}_1$$

Combinamos os vetores via operadores

média, Hadamard, L1 e L2



Tarefas de regressão e classificação:

`sklearn.linear_model.LogisticRegression`

`sklearn.neighbors.KNeighborsClassifier`

`sklearn.neighbors.KNeighborsRegressor`

Prevendo parcerias em redes criminosas

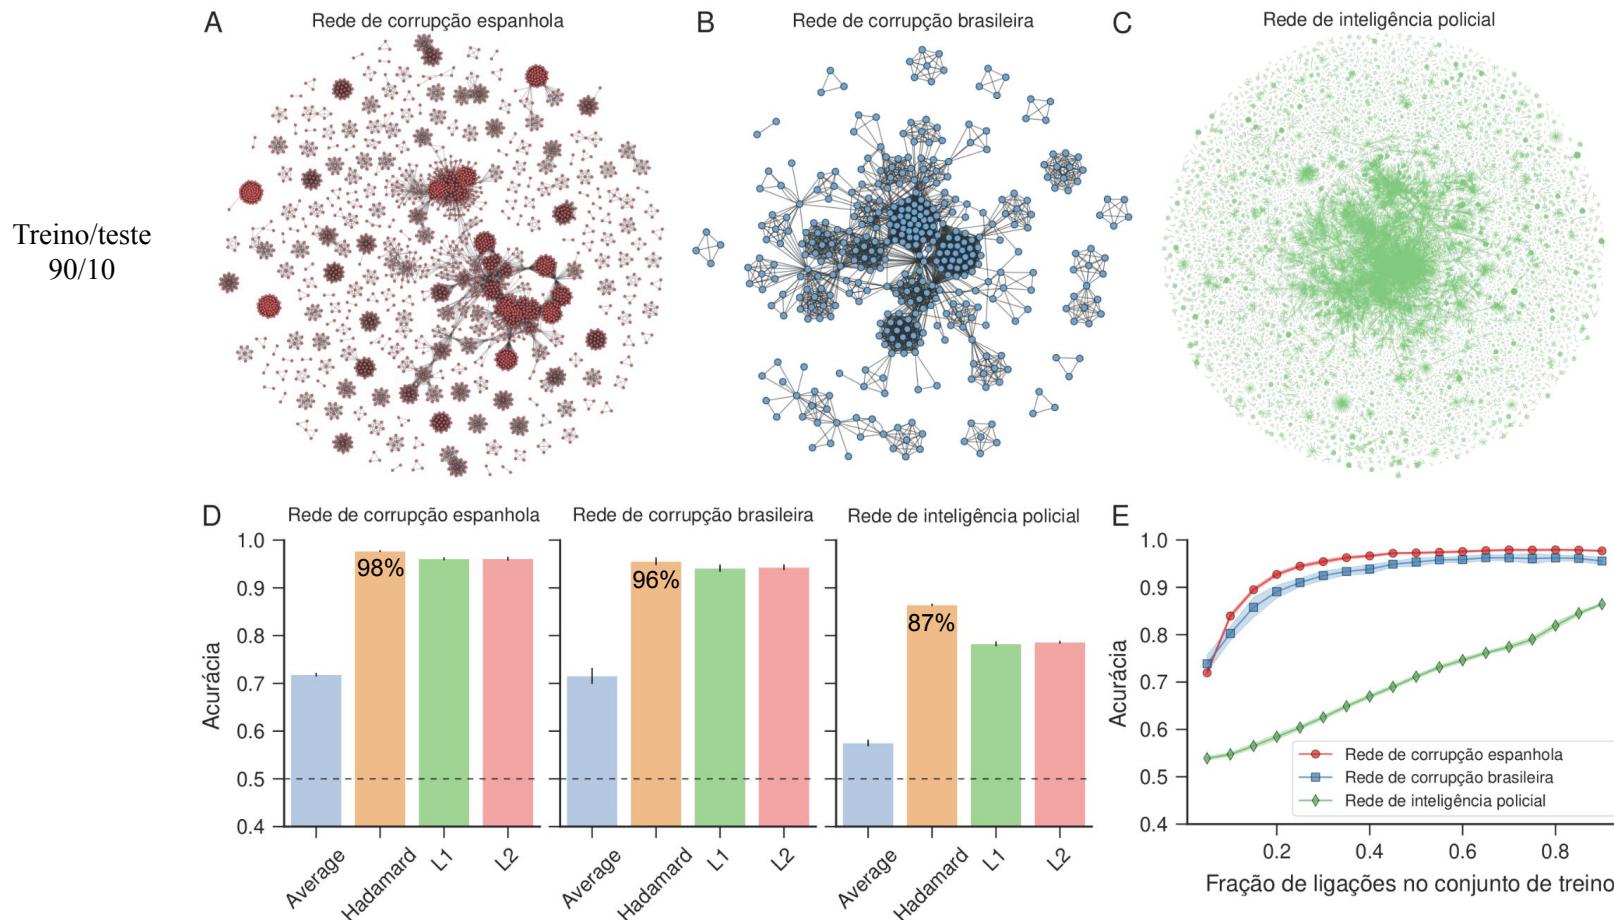


Figura 16: Visualização comparativa entre as redes de corrupção (A) espanhola e (B) brasileira e a rede de inteligência policial (C). (D) Acurácia do classificador logístico usando diferentes operadores binários. (E) Acurácia do classificador logístico para cada rede criminosa em função da fração dos vértices usados no conjunto de treinamento.

Comparação com outros métodos de representação de grafos

LINE: Large-scale Information Network Embedding

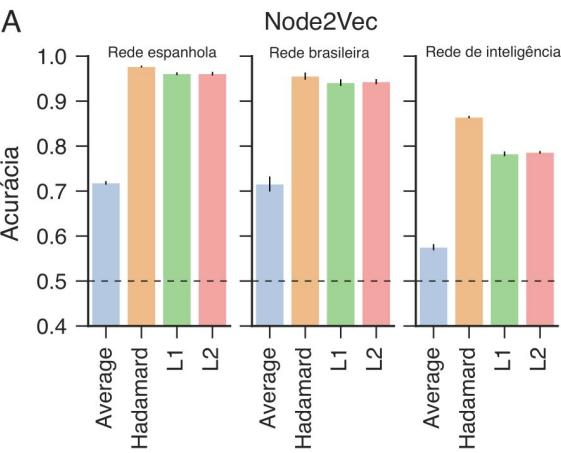
Jian Tang¹, Meng Qu², Mingzhe Wang³, Ming Zhang³, Jun Yan¹, Qiaozhu Mei³

¹Microsoft Research Asia, {jiatang, junyan}@microsoft.com

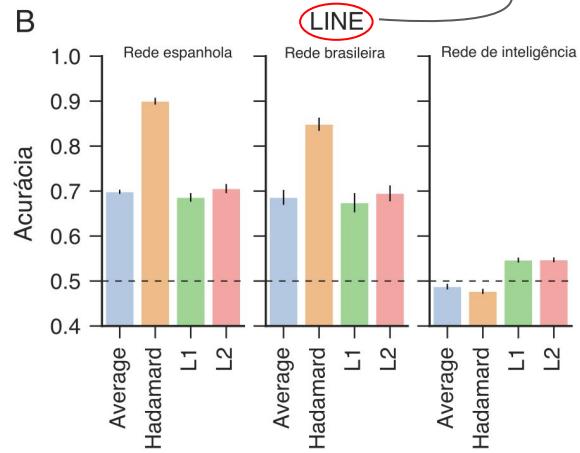
²School of EECS, Peking University, {mnqu, wangmingzhe, mzhang_cs}@pku.edu.cn

³School of Information, University of Michigan, qmei@umich.edu

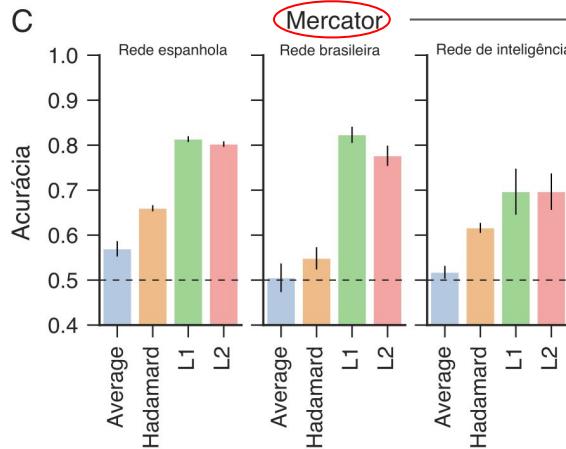
A



B



C



Mercator: uncovering faithful hyperbolic embeddings of complex networks

Guillermo García-Pérez^{1,2,8}, Antoine Allard^{3,4,8}, M Ángeles Serrano^{5,6,7} and Marián Boguña^{5,6}

Figura 17: Acurácia média de classificadores logísticos treinados para prever ligações nas redes criminosas usando vértices de entrada obtidos via (A) Node2Vec, (B) LINE e (C) Mercator.

Classificando a associação entre envolvidos da rede de inteligência policial

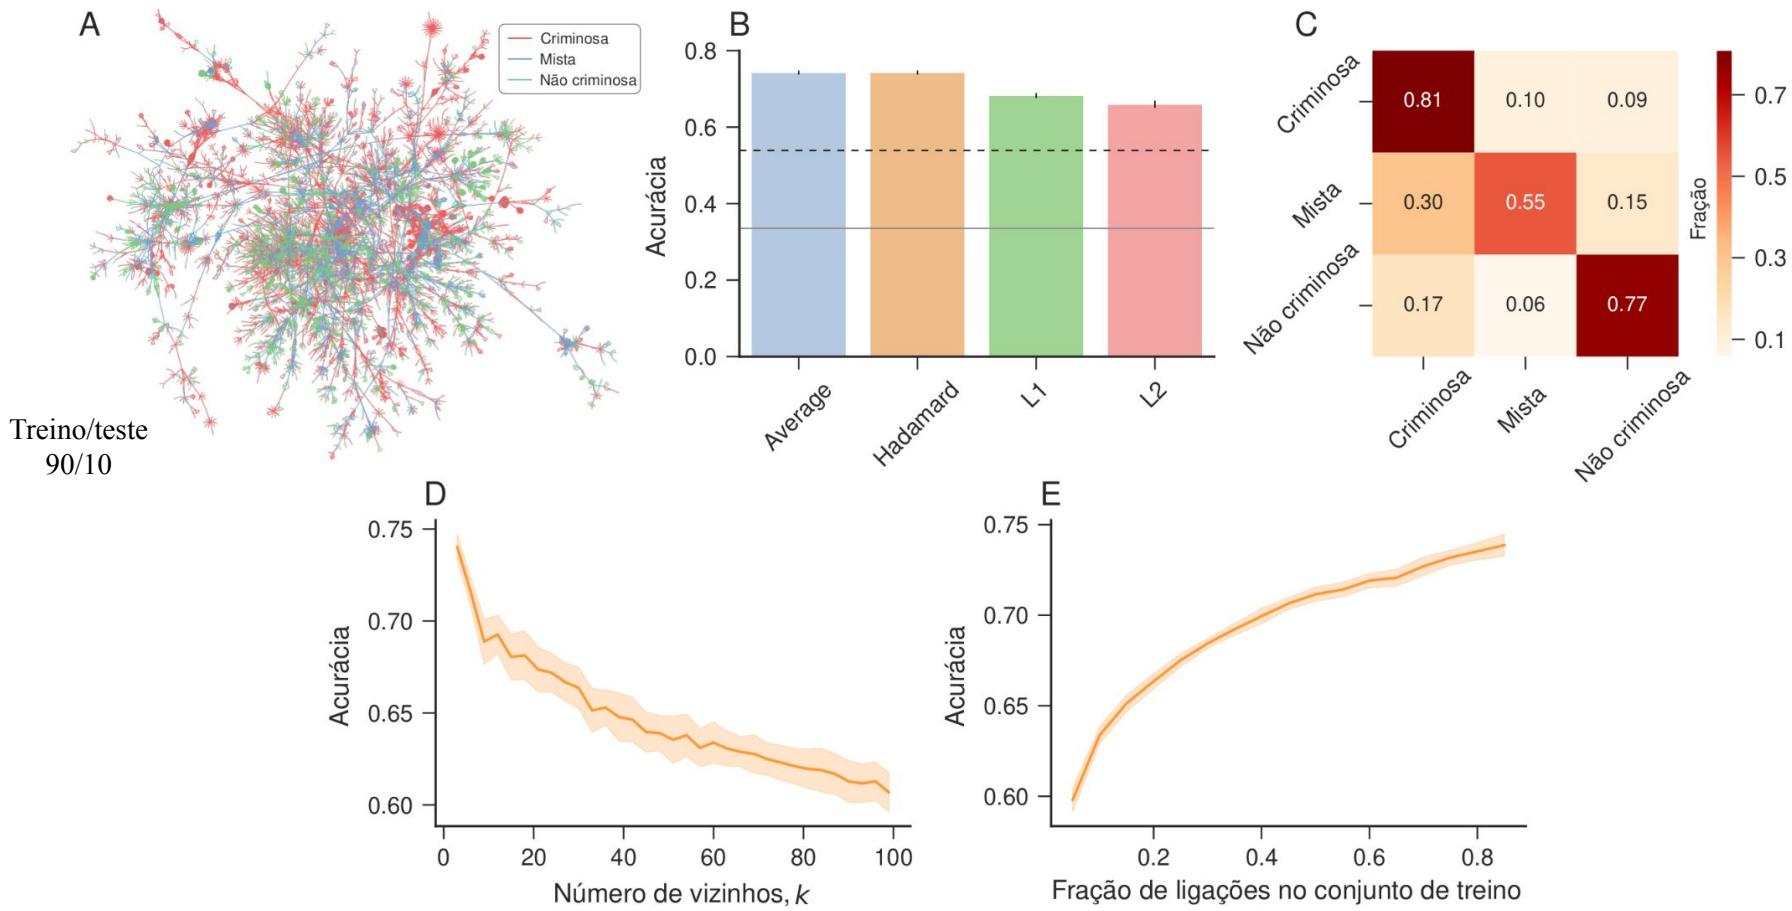


Figura 18: (A) Visualização da maior componente da rede de inteligência policial. (B) Acurácia média dos classificadores kNN treinados com vértices obtidos via *Node2Vec* e diferentes operadores binários. (C) Matriz de confusão relacionada às previsões do classificador e usando o operador Hadamard. (D) Acurácia média do classificador kNN em função do número de vizinhos. (E) Acurácia média do classificador kNN em função da fração de ligações nos conjuntos de treinamento.

Prevendo valores de transações bancárias na rede de crime financeiros

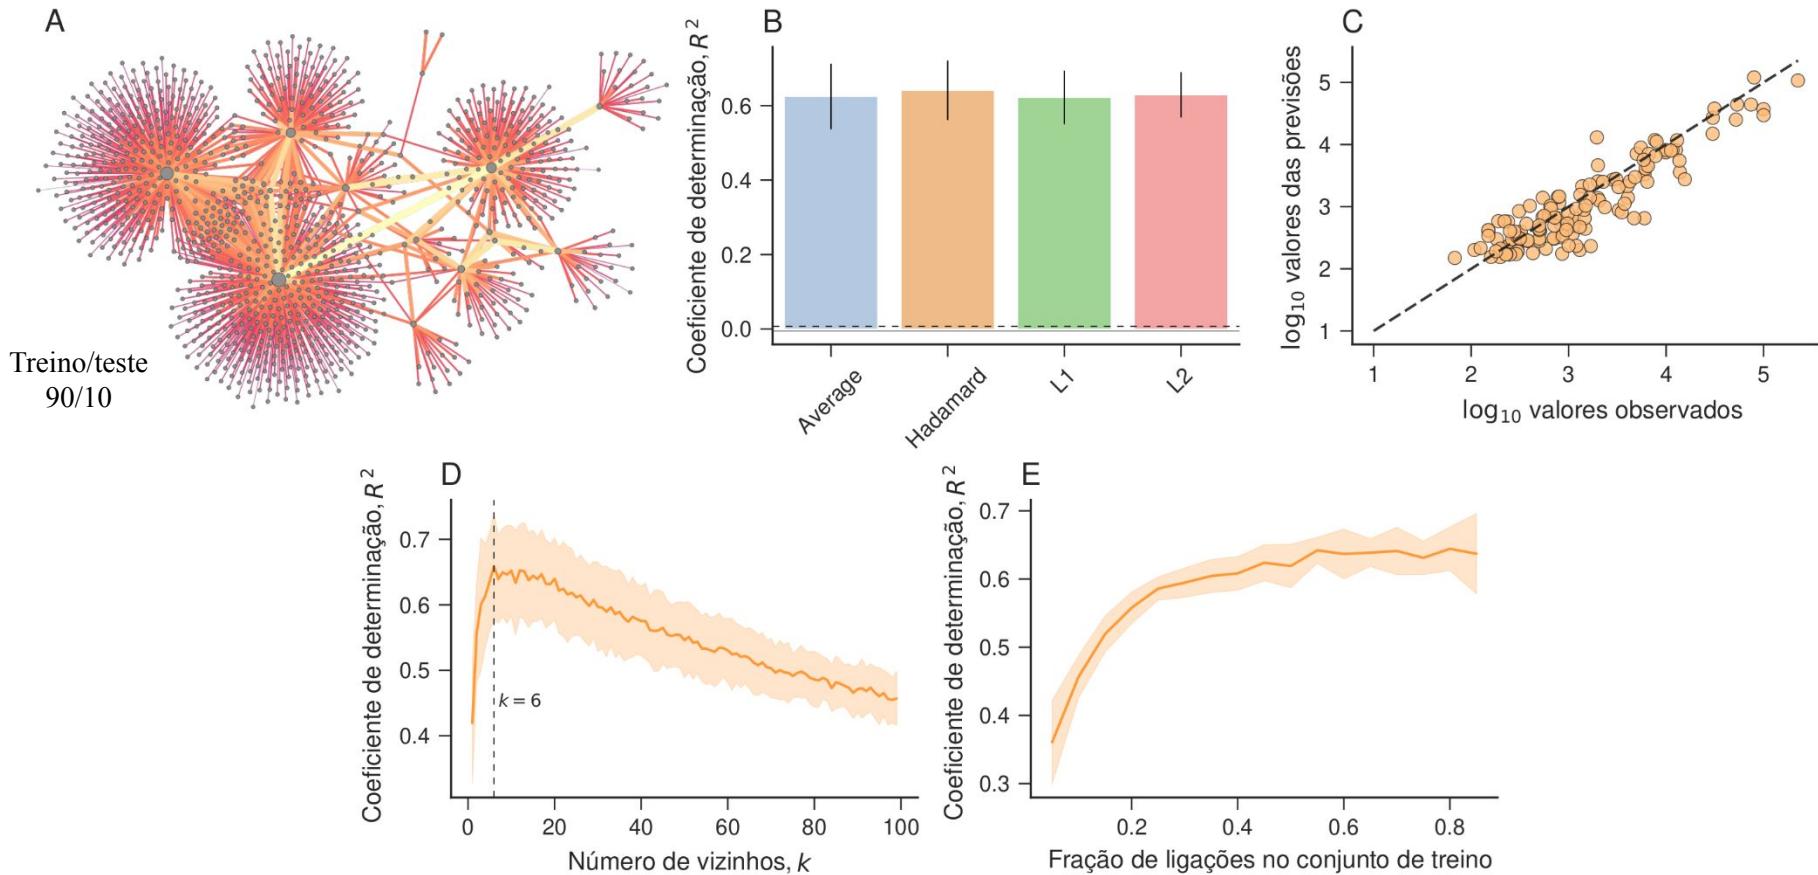
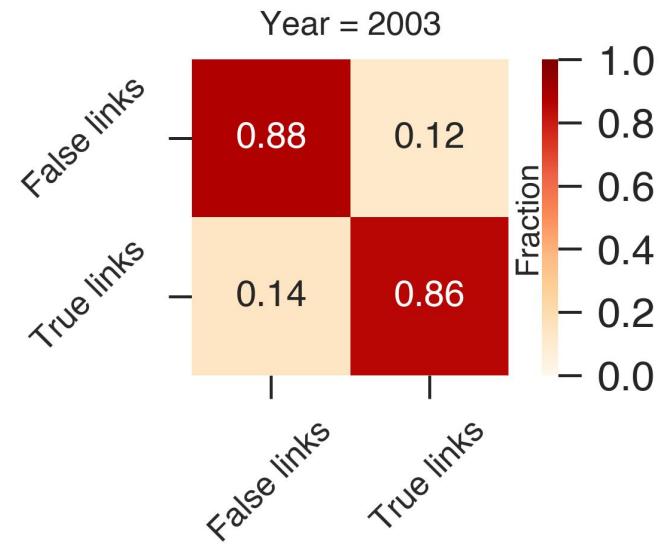
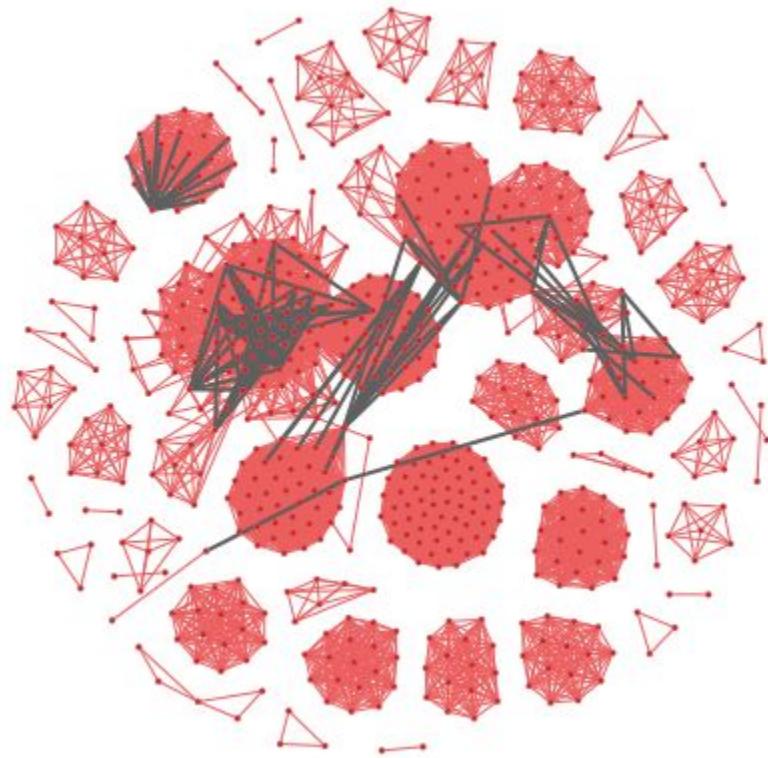


Figura 19: (A) Visualização da rede de crimes financeiros. (B) Coeficiente de determinação (R^2) médio da associação entre as transações previstas e observadas. (C) Exemplo típico da relação entre o logaritmo das quantidades de dinheiro previstas e observadas nas ligações dos conjuntos de teste. (D) Valor médio do coeficiente R^2 em função do número de vizinhos do regressor kNN . (E) Valor médio do coeficiente R^2 em função da fração de ligações no conjunto de treinamento.

Prevendo parcerias futuras nas redes de corrupção

$$G_Y = G_{2003}$$



Prevendo parcerias futuras nas redes de corrupção

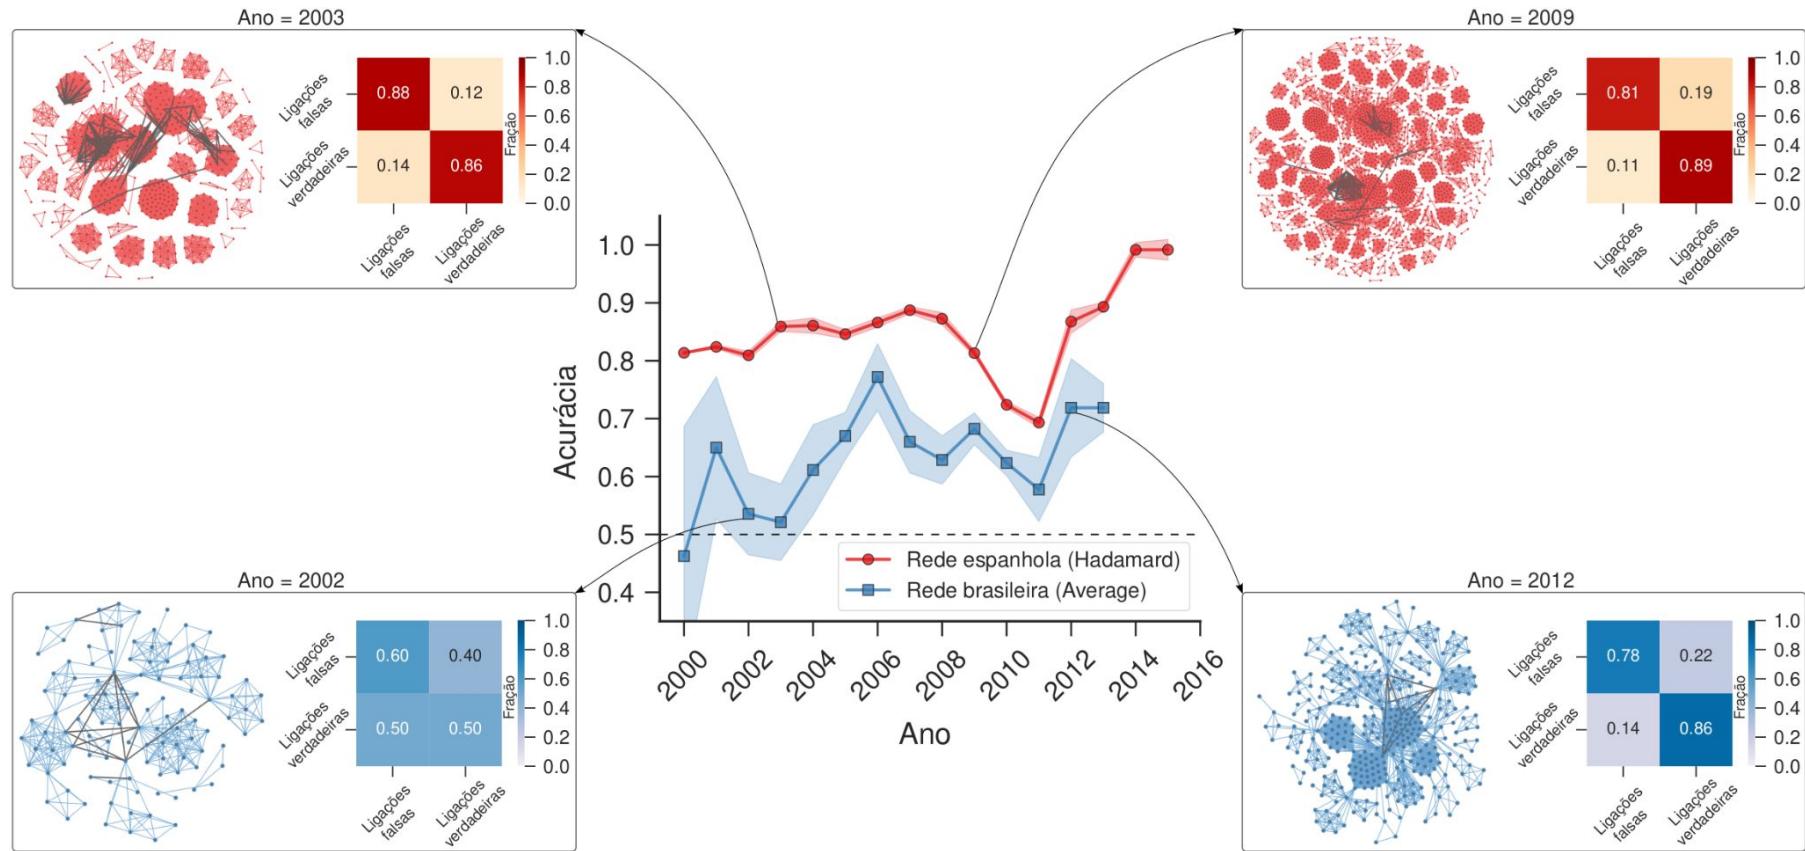


Figura 20: Acurácia média da tarefa de prever ligações futuras nas redes de corrupção espanhola e brasileira. As inserções mostram visualizações de redes acompanhadas de matrizes de confusão associadas às tarefas de prever se as ligações futuras são verdadeiras ou falsas.

Prevendo parcerias futuras nas redes de corrupção

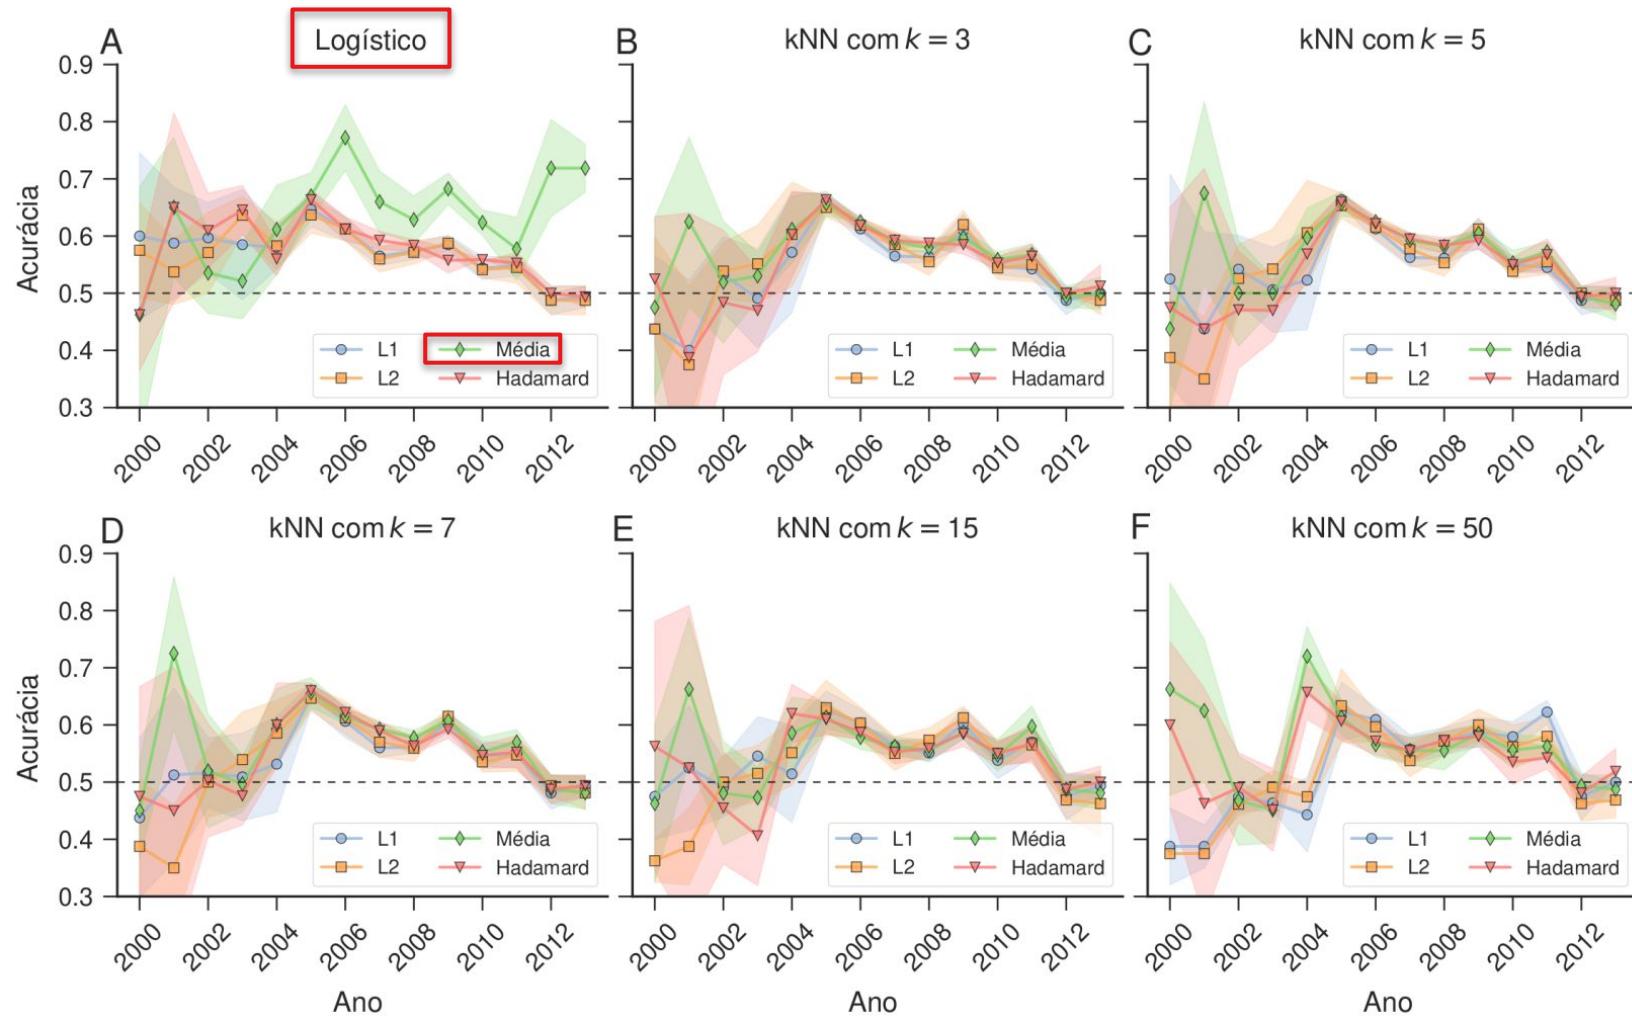


Figura 21: (Brasil) Acurácia média da previsão de parcerias futuras na rede de corrupção brasileira em função do ano limiar para diferentes operadores binários. (A) Resultados obtidos usando classificadores logísticos, enquanto os outros painéis [(B), (C), (D) e (E)] mostram a acurácia para classificadores kNN com diferentes números de vizinhos.

Prevendo parcerias futuras nas redes de corrupção

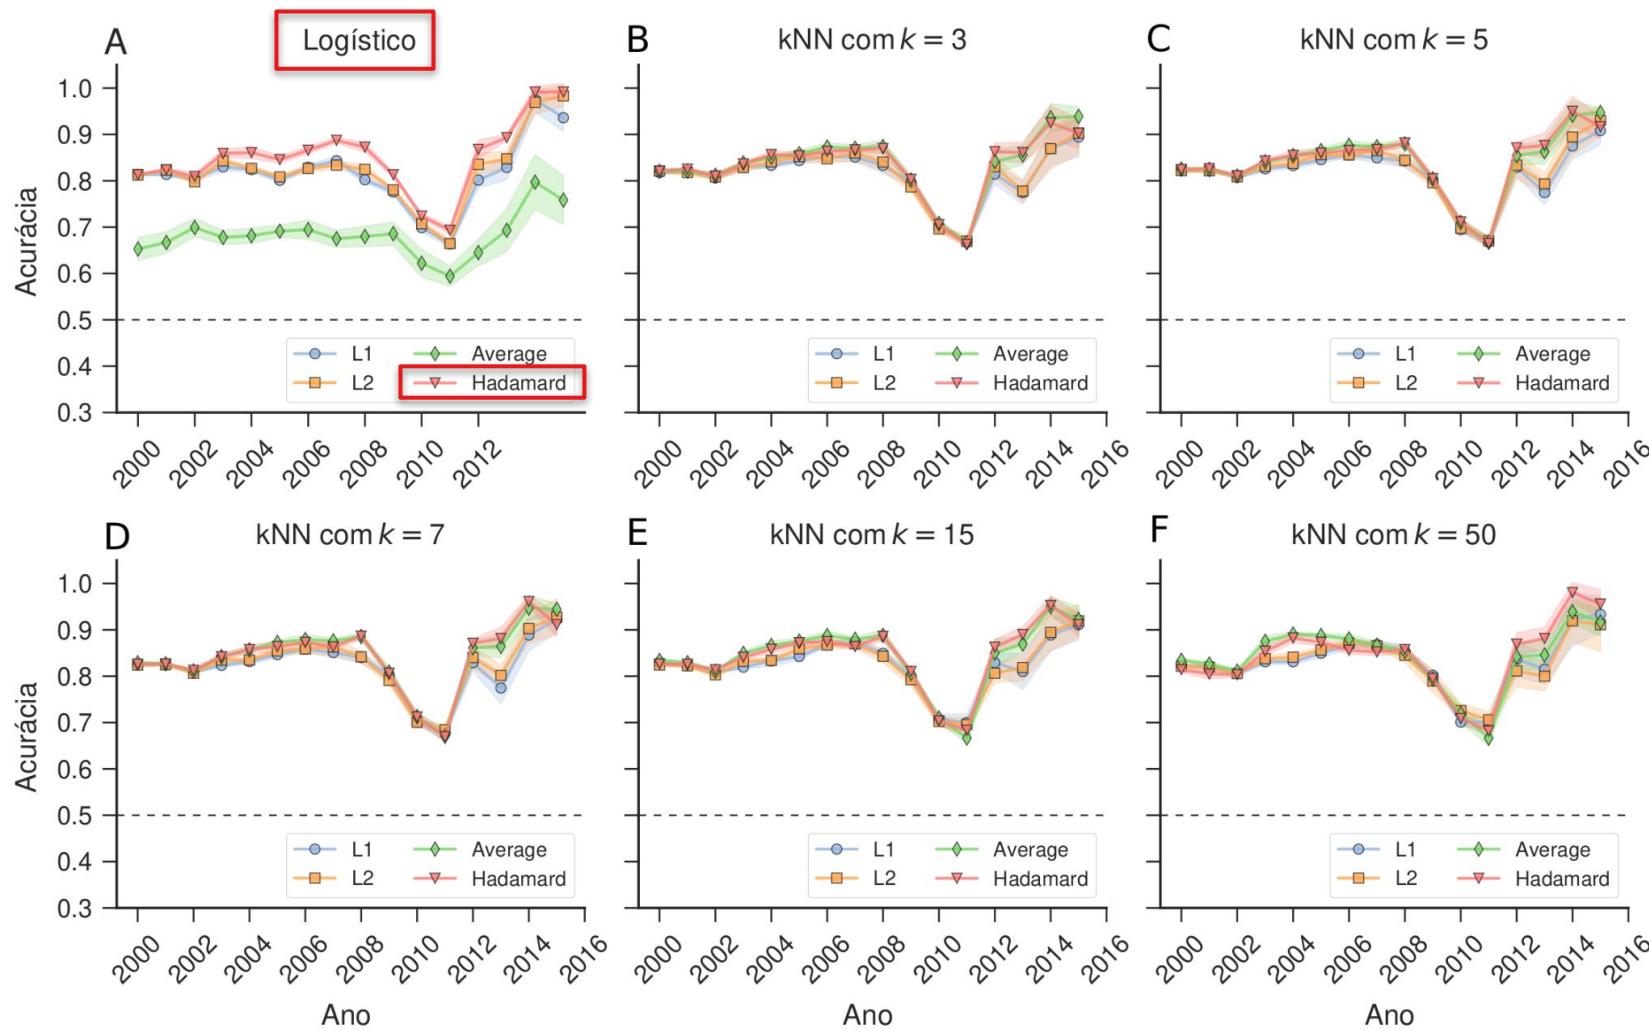


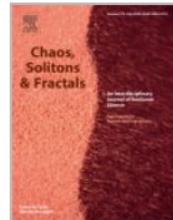
Figura 22: (Espanha) Acurácia média da previsão de parcerias futuras na rede de corrupção espanhola em função do ano limiar para diferentes operadores binários. (A) Resultados obtidos usando classificadores logísticos, enquanto os outros painéis [(B), (C), (D) e (E)] mostram a acurácia para classificadores kNN com diferentes números de vizinhos.



ELSEVIER

Chaos, Solitons & Fractals

Volume 172, July 2023, 113579



Deep learning criminal networks

Haroldo V. Ribeiro^a   , Diego D. Lopes^a, Arthur A.B. Pessa^a, Alvaro F. Martins^a,
Bruno R. da Cunha^{b c}, Sebastián Gonçalves^d, Ervin K. Lenzi^e, Quentin S. Hanley^f,
Matjaž Perc^{g h i j k}  

Show more ▾

+ Add to Mendeley  Share  Cite

<https://doi.org/10.1016/j.chaos.2023.113579> ↗

Get rights and content ↗

O algoritmo *GraphSAGE*

Inductive Representation Learning on Large Graphs

William L. Hamilton*

wleif@stanford.edu

Rex Ying*

rexying@stanford.edu

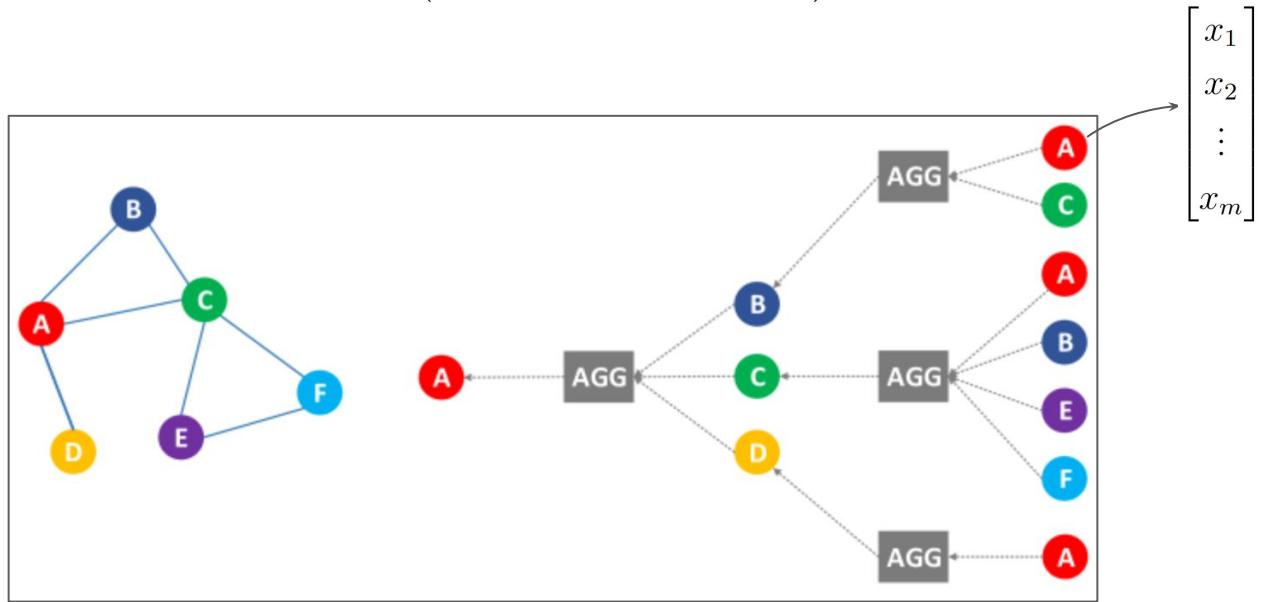
Jure Leskovec

jure@cs.stanford.edu

$$h_{\mathcal{N}_u}^k = \text{AGG}_k \left(\{h_v^{k-1}, \forall v \in \mathcal{N}_u\} \right),$$

$$h_u^k = \sigma \left(W^k \cdot \text{CONCAT}(h_u^k, h_{\mathcal{N}_u}^k) \right)$$

Node2Vec



<https://www.arxiv-vanity.com/papers/2103.16329/>

Arquitetura de redes neurais usada para prever ligações nas redes criminosas.

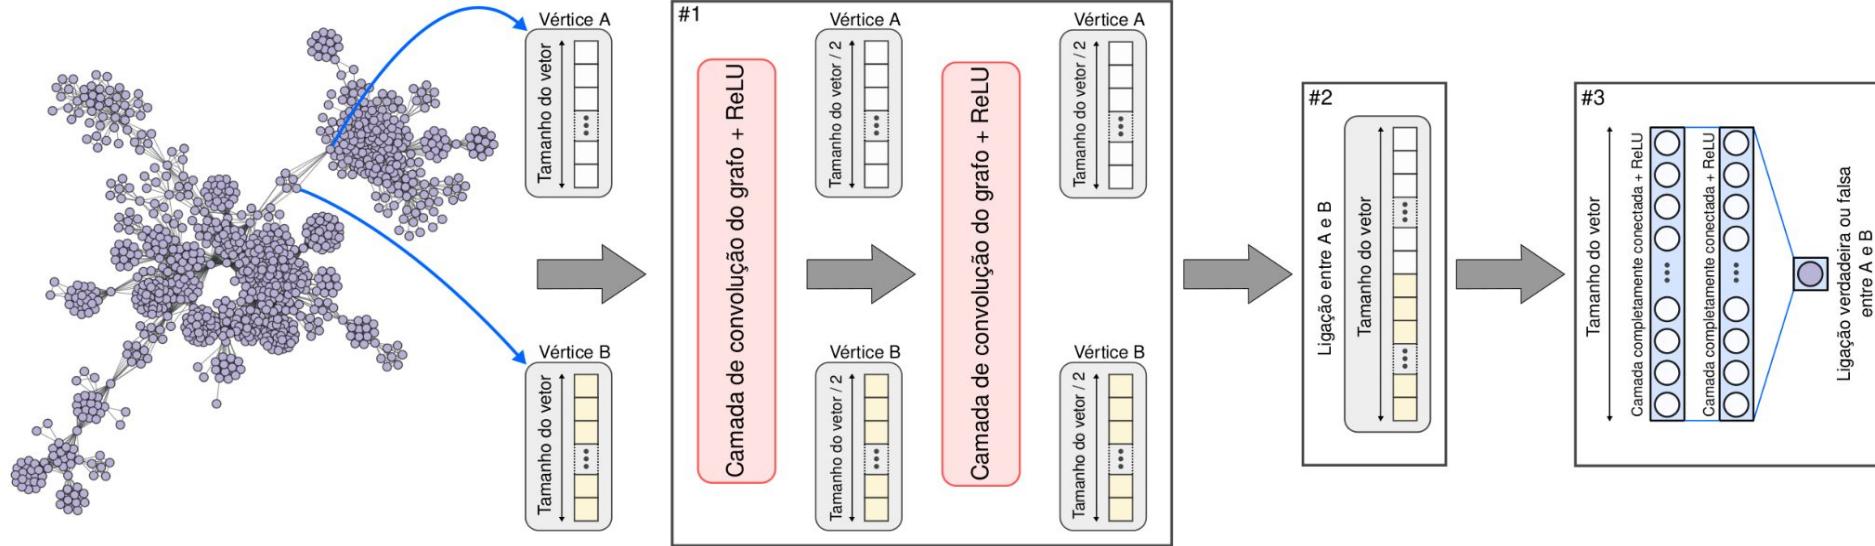


Figura 23: Representação esquemática da arquitetura de redes neurais usada para prever ligações nas redes criminosas.

Arquitetura de redes neurais usada para prever ligações nas redes criminosas.

UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction

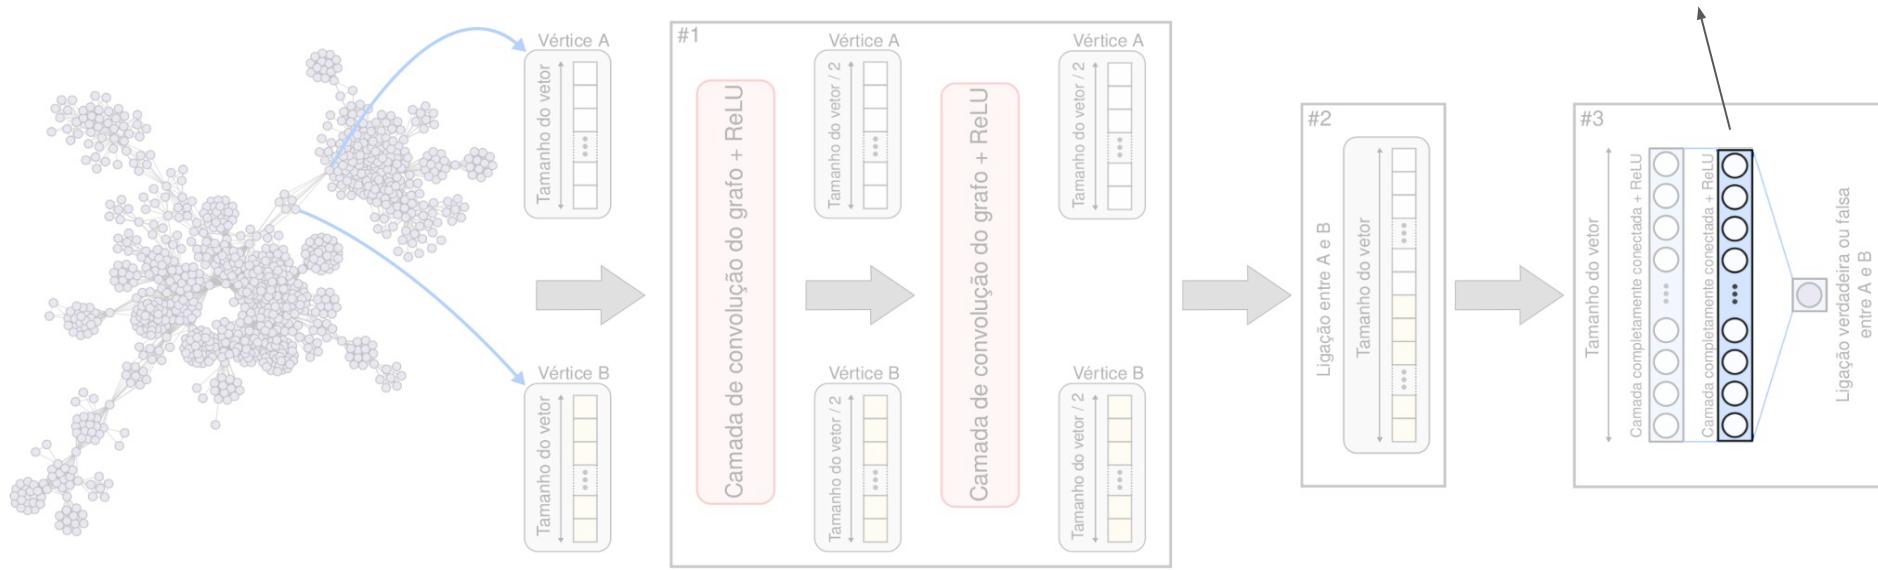


Figura 23: Representação esquemática da arquitetura de redes neurais usada para prever ligações nas redes criminosas.

Prevendo parcerias em redes criminosas

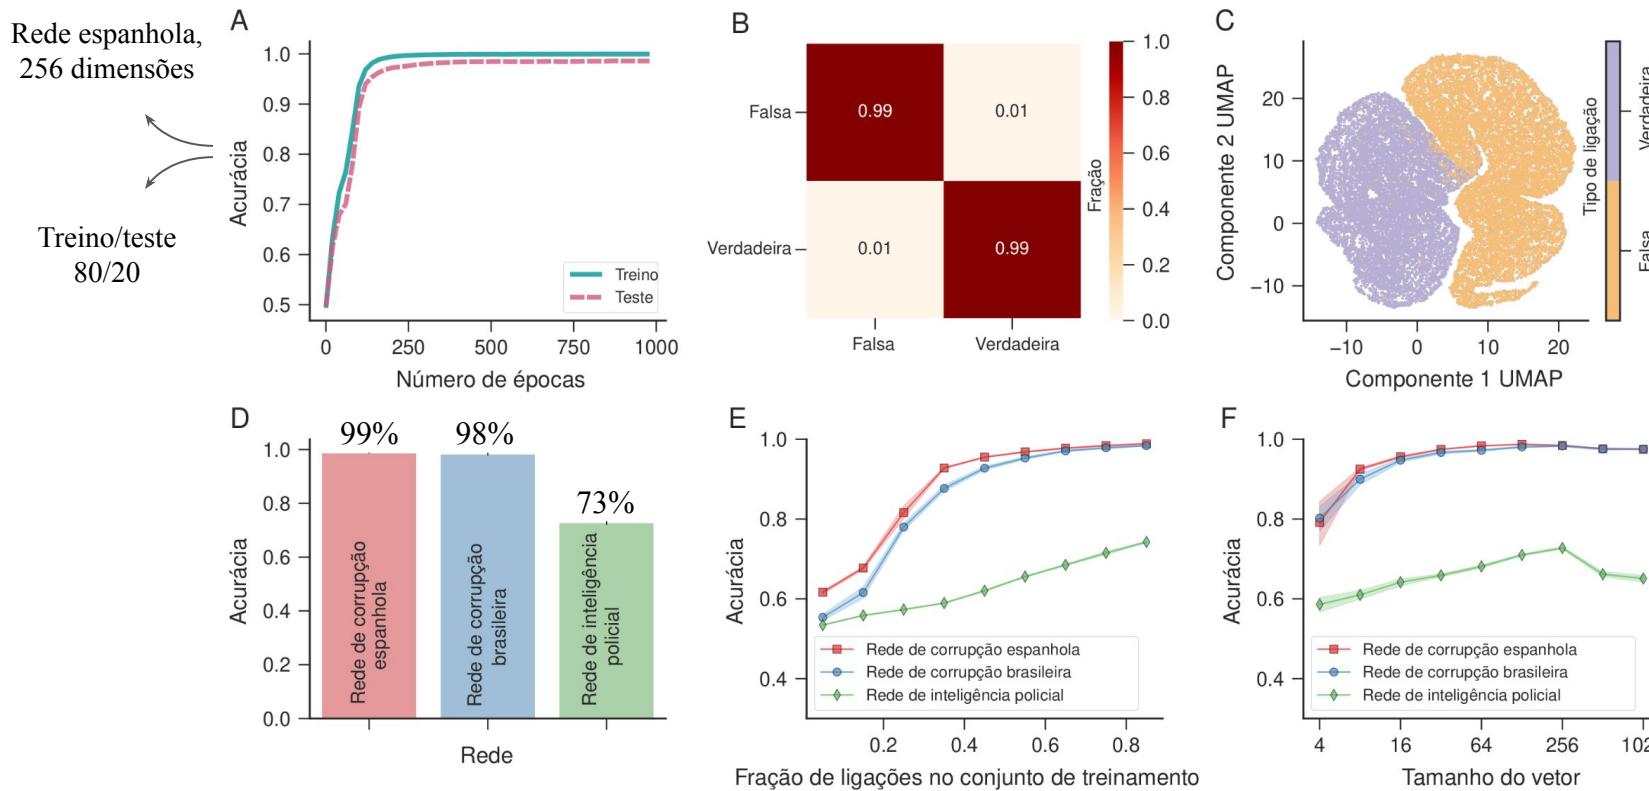


Figura 24: (A) Curvas de acurácia do modelo em função do número de épocas utilizadas durante a fase de treinamento. (B) Exemplo de uma matriz de confusão obtida ao aplicar o modelo treinado ao conjunto de teste. (C) Visualização típica dos vetores da última camada do modelo projetados num plano bidimensional. (D) Acurácia média das previsões do modelo nas redes de corrupção e na rede de inteligência policial. (E) Acurácia média do modelo em cada rede criminosa em função da fração de ligações do conjunto de treinamento. (F) Acurácia média do modelo em cada rede criminosa em função da dimensão do vetor inicial.

Arquitetura de redes neurais utilizada para determinar o tipo de relacionamento entre envolvidos da rede de inteligência policial

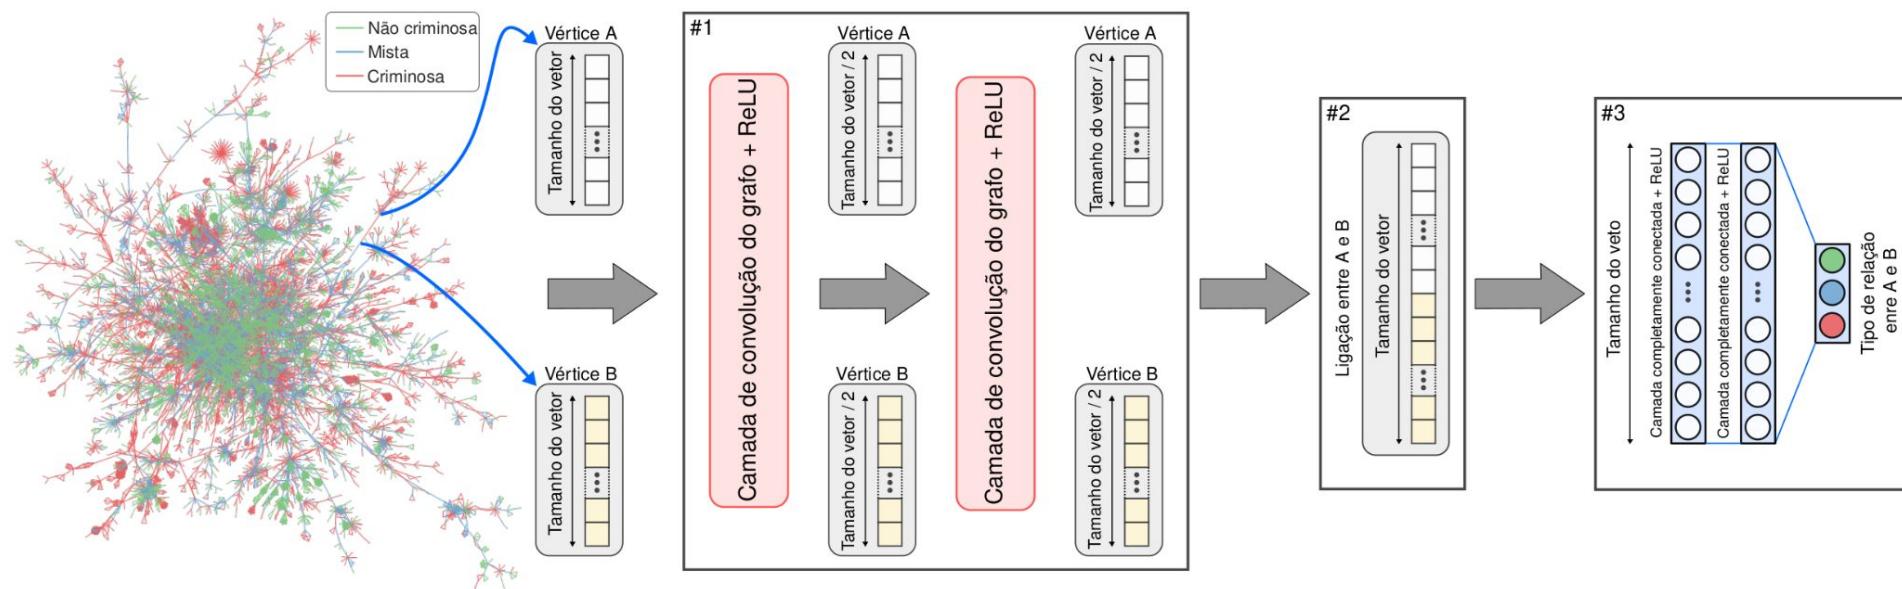


Figura 25: Representação esquemática da arquitetura de redes neurais utilizada para determinar o tipo de relacionamento entre envolvidos da rede de inteligência policial.

Classificando a associação entre envolvidos da rede de inteligência policial

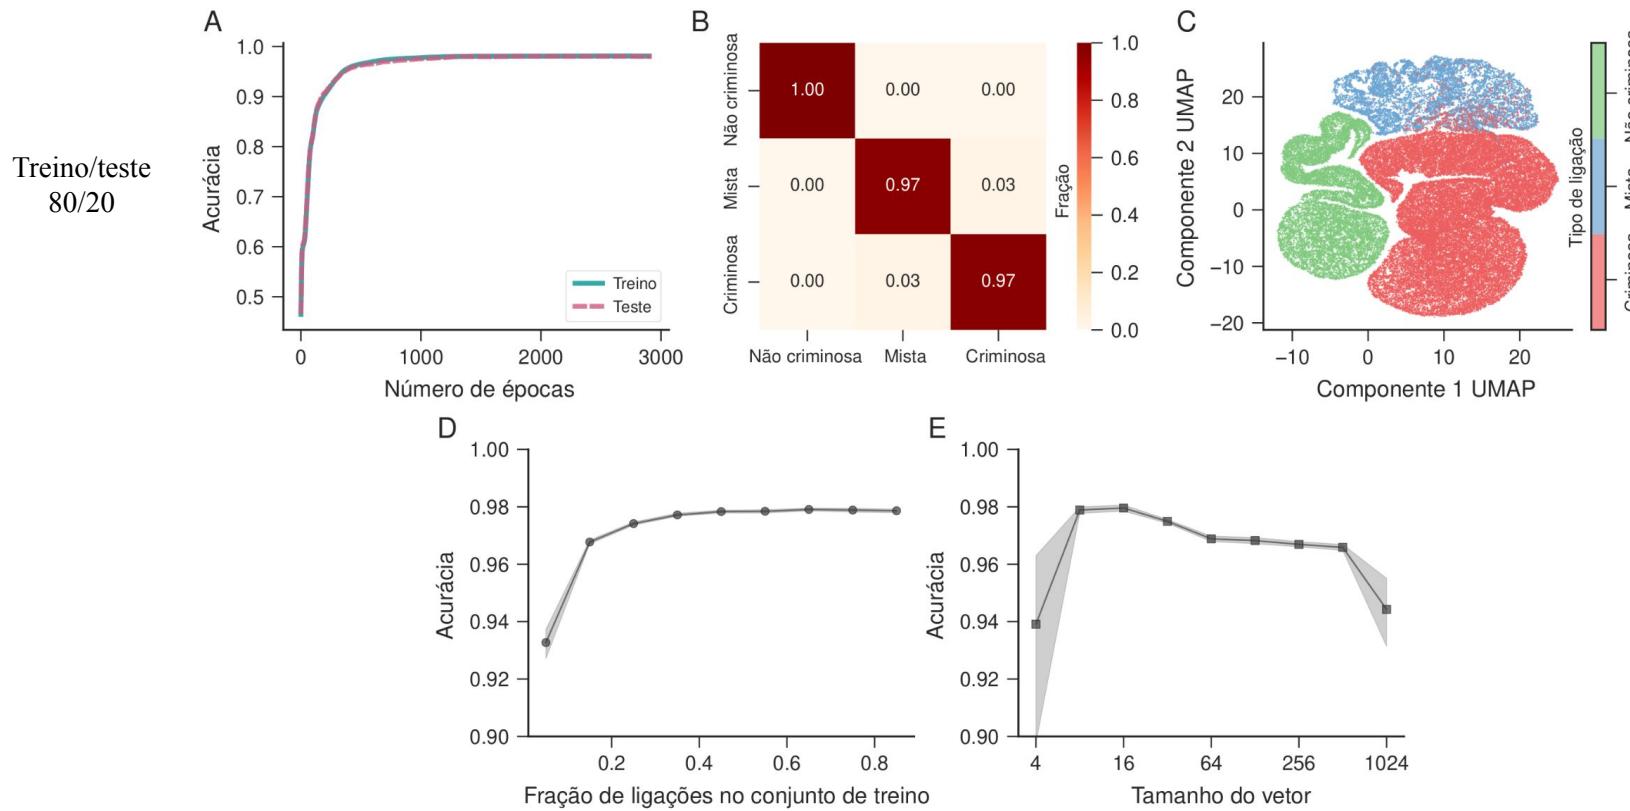


Figura 26: (A) Curvas de acurácia do modelo em função do número de épocas utilizadas durante a fase de treinamento. (B) Exemplo de uma matriz de confusão obtida ao aplicar o modelo treinado ao conjunto de teste. (C) Visualização típica dos vetores da última camada do modelo projetados num plano bidimensional. (D) Acurácia média do modelo sobre o conjunto de teste em função da fração de ligações do conjunto de treinamento. (E) Acurácia média do modelo sobre o conjunto de teste em função da dimensão do vetor inicial.

Arquitetura de redes neurais usada para prever a quantidade total de dinheiro trocado entre agentes da rede de crimes financeiros

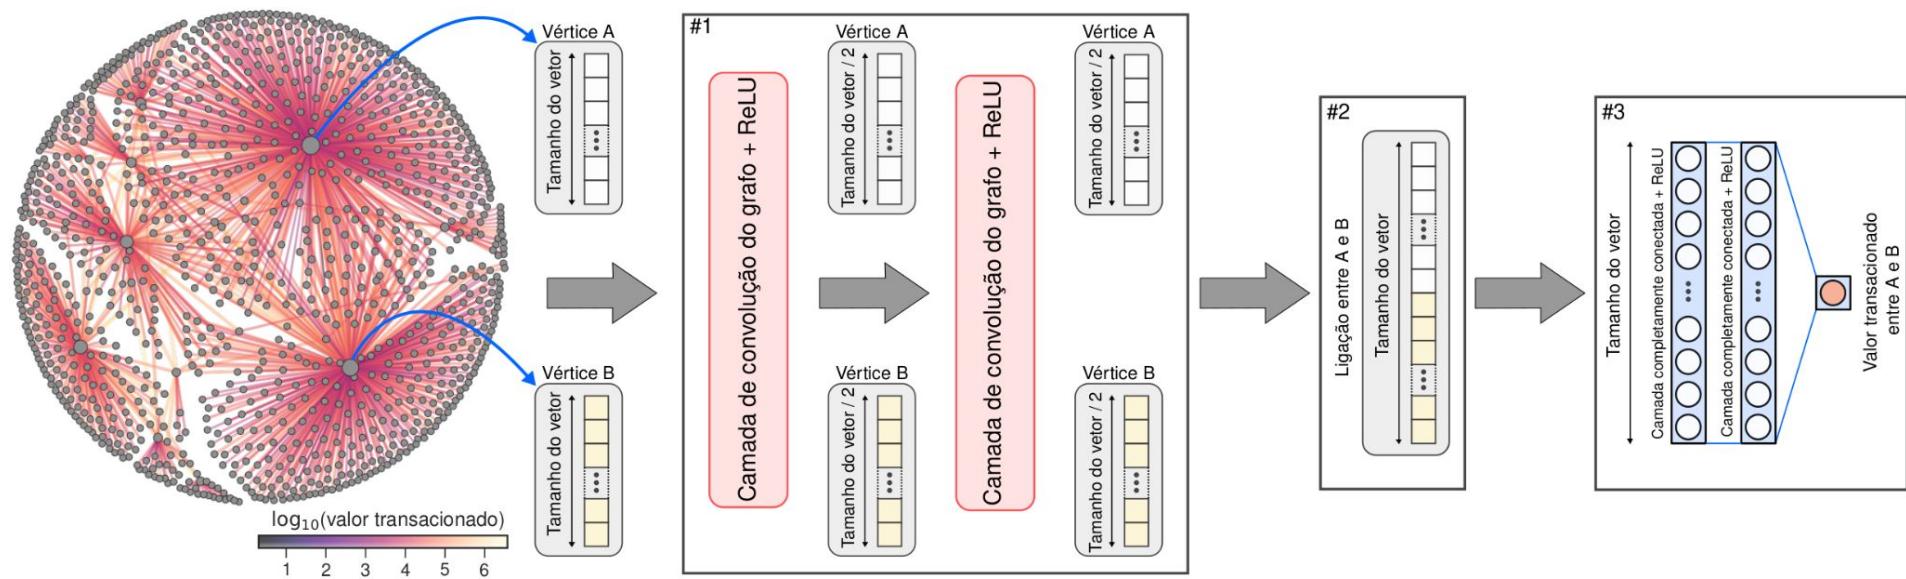


Figura 27: Representação esquemática da arquitetura de redes neurais usada para prever a quantidade total de dinheiro trocado entre agentes da rede de crimes financeiros.

Prevendo valores de transações bancárias na rede de crime financeiros

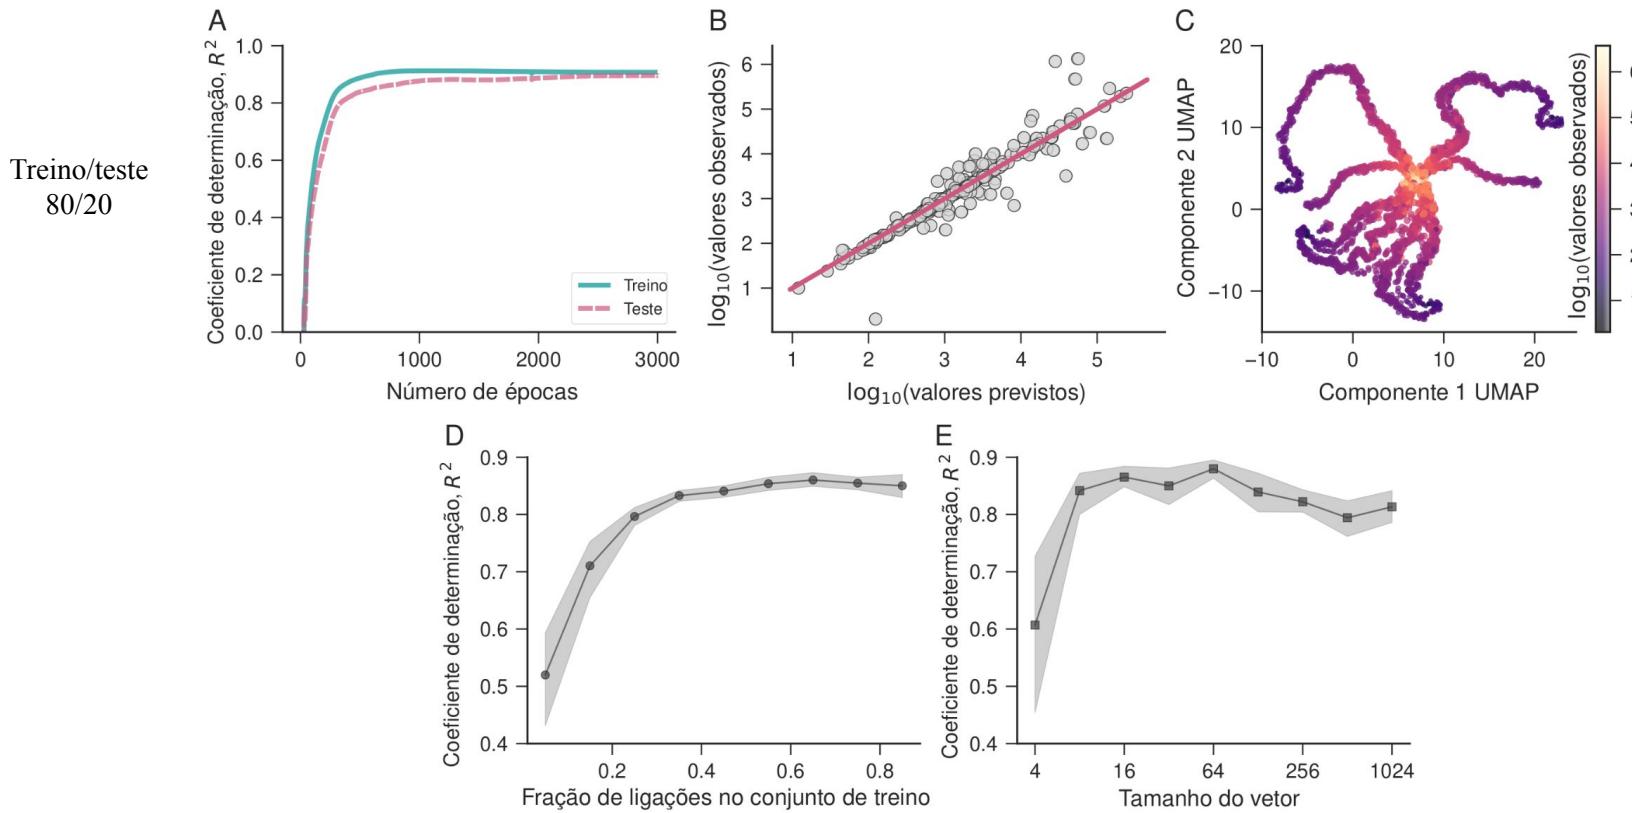


Figura 28: (A) Curvas do coeficiente R2 em função do número de épocas usadas durante a fase de treinamento. (B) Exemplo típico da relação entre os valores observados e preditos no conjunto de teste usando o modelo treinado. (C) Visualização típica dos vetores da última camada projetados num plano bidimensional. (D) Valor médio do coeficiente R2 em função da fração de ligações no conjunto de treinamento. (E) Valor médio do coeficiente R2 em função da dimensão do vetor inicial.

Arquitetura de redes neurais usada para prever futuras ligações nas redes de corrupção

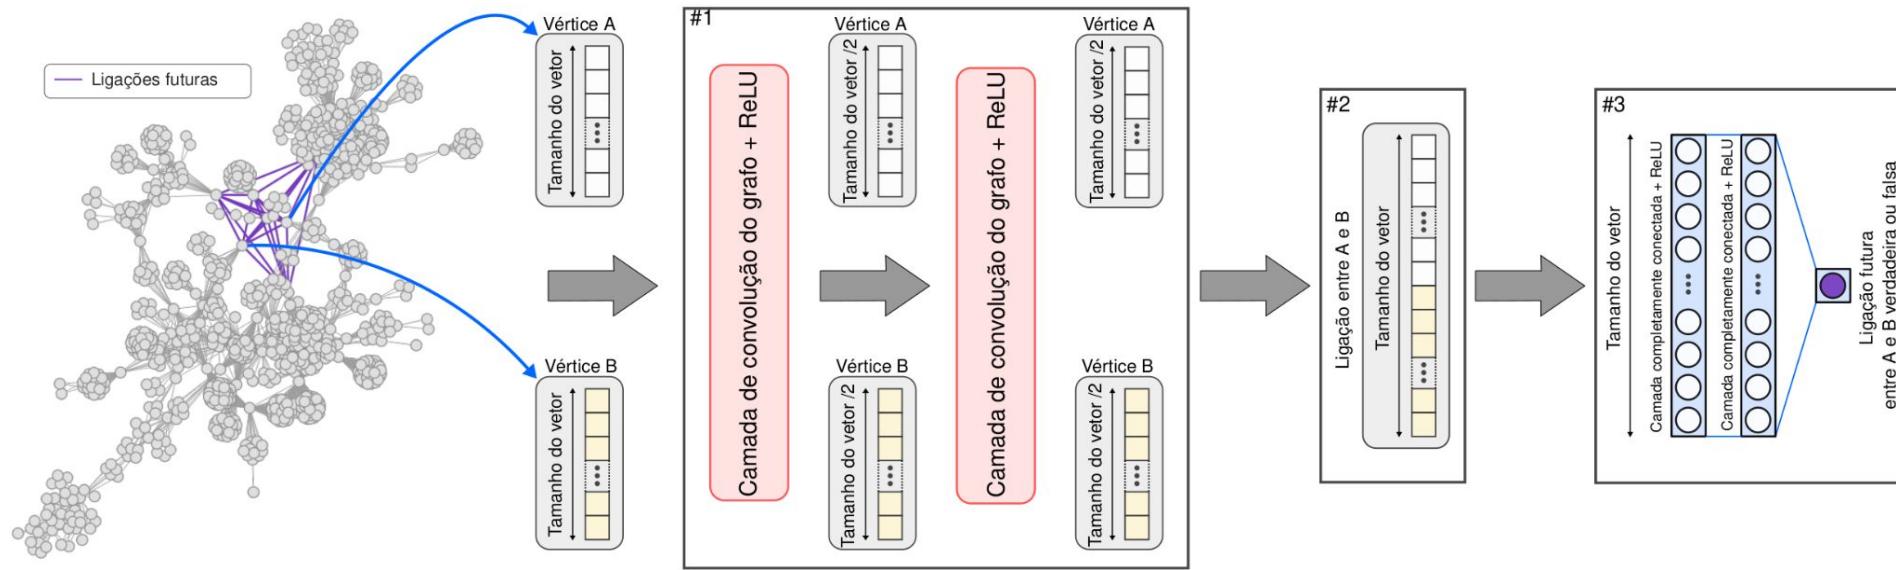


Figura 29: Representação esquemática da arquitetura de redes neurais usada para prever futuras ligações nas redes de corrupção.

Prevendo parcerias futuras nas redes de corrupção

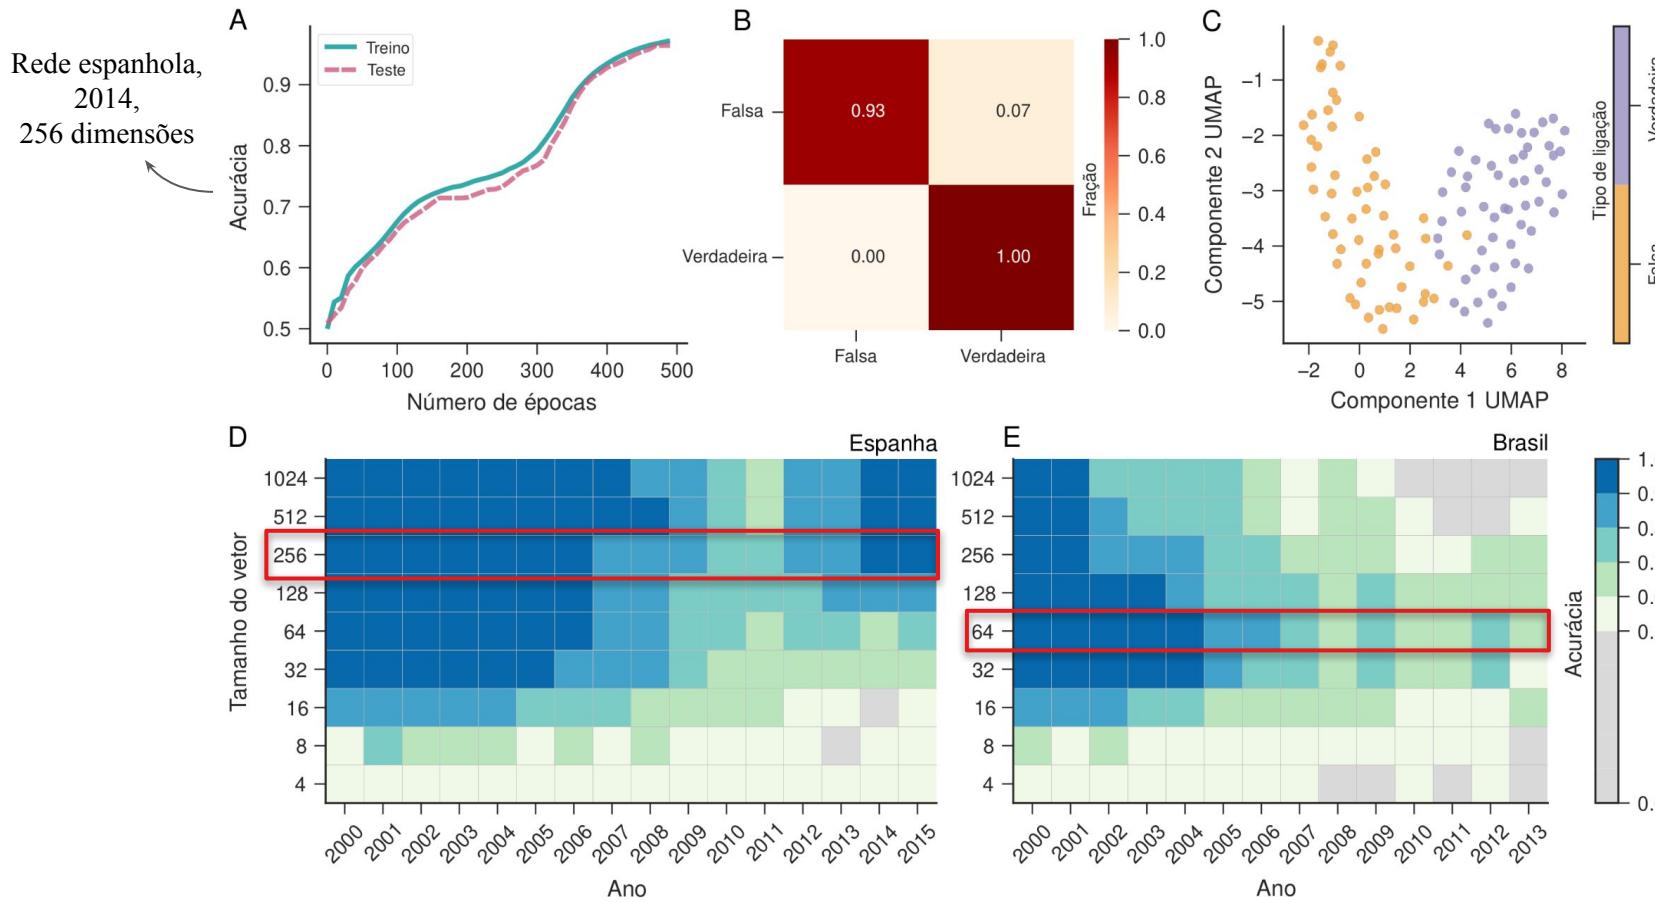


Figura 30: (A) Curvas de acurácia do modelo em função do número de épocas utilizadas durante a fase de treinamento. (B) Exemplo de uma matriz de confusão obtida ao aplicar o modelo treinado ao conjunto de teste. (C) Visualização típica dos vetores da última camada do modelo projetados no plano bidimensional. Acurácia média do modelo nos conjuntos de teste das redes (D) espanhola e (E) brasileira considerando diferentes anos e dimensões dos vetores de entrada.

Arquitetura de redes neurais usada para determinar se um agente da rede de corrupção se tornará reincidente

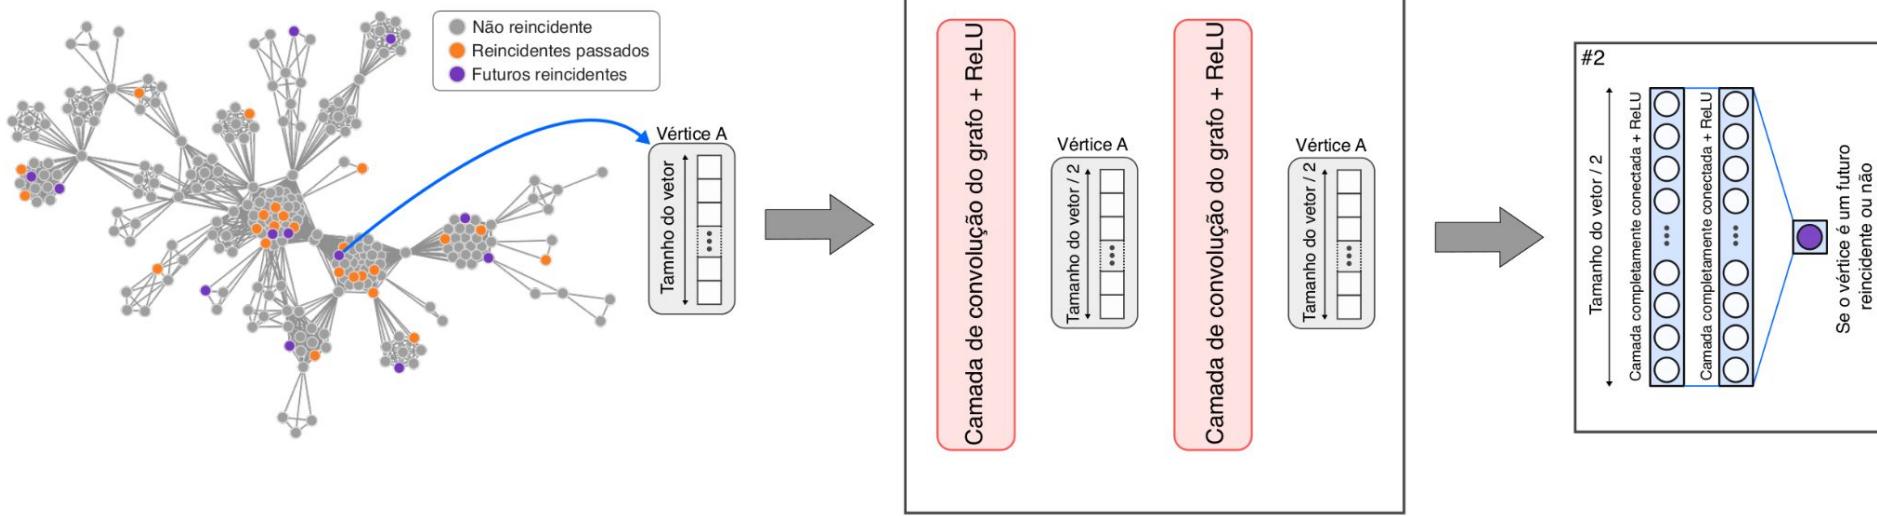


Figura 31: Representação esquemática da arquitetura de redes neurais usada para determinar se um agente da rede de corrupção se tornará reincidente.

Prevendo a ocorrência de envolvidos reincidentes

Rede brasileira,
2011,
256 dimensões

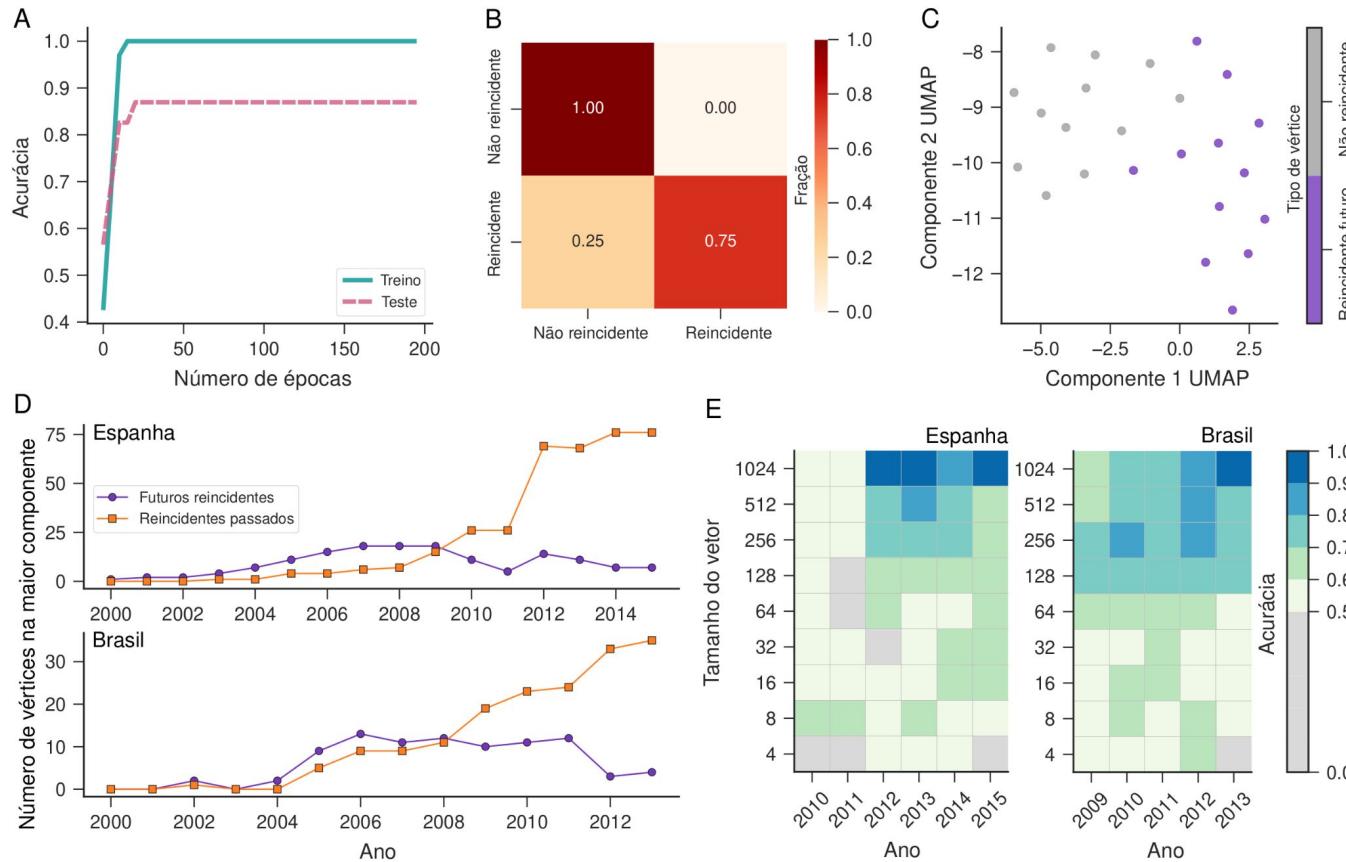


Figura 32: (A) Curvas de acurácia do modelo em função do número de épocas utilizadas durante a fase de treinamento. (B) Exemplo de uma matriz de confusão obtida ao aplicar o modelo treinado ao conjunto de teste. (C) Visualização típica dos vetores da última camada do modelo projetados no plano bidimensional. (D) Número de agentes reincidentes futuros e passados na componente gigante das redes de corrupção espanhola e brasileira em função do tempo. (E) Acurácia média do modelo nos conjuntos de teste ao considerar diferentes anos das redes de corrupção espanhola e brasileira, bem como diferentes dimensões dos vetores de entrada.

Conclusões

scientific reports

Universality of political corruption networks

Alvaro F. Martins, Bruno R. da Cunha, Quentin S. Hanley, Sebastián Gonçalves, Matjaž Perc & Haroldo V. Ribeiro

Investigamos redes de corrupção de dois países distintos e encontramos padrões universais de estrutura e dinâmica nessas redes;

scientific reports

Machine learning partners in criminal networks

Diego D. Lopes, Bruno R. da Cunha, Alvaro F. Martins, Sebastián Gonçalves, Ervin K. Lenzi, Quentin S. Hanley, Matjaž Perc & Haroldo V. Ribeiro

Aplicamos algoritmos de aprendizagem estatística em redes criminosas e alcançamos boas acurárias na previsão de variáveis relacionadas a essas redes;



Chaos, Solitons & Fractals

Volume 172, July 2023, 113579



Deep learning criminal networks

Haroldo V. Ribeiro^a , Diego D. Lopes^a, Arthur A.B. Pessa^a, Alvaro F. Martins^a, Bruno R. da Cunha^{b,c}, Sebastián Gonçalves^d, Ervin K. Lenzi^e, Quentin S. Hanley^f, Matjaž Perc^{g,h,i,j,k}

Evidenciamos o imenso potencial dos modelos de aprendizado profundo na exploração, previsão e classificação de propriedades de redes criminosas;

Muito obrigado!

